



ESCUELA TÉCNICA SUPERIOR DE INGENIERÍA DE
INFORMÁTICA

MÁSTER UNIVERSITARIO EN VISIÓN ARTIFICIAL

TRABAJO FIN DE MÁSTER

**Monitorización Visual de Tráfico Rodado
usando DeepLearning**

Autor: Jessica Fernández Martínez

Tutor: José María Cañas Plaza

Co-tutor: Redouane Kachach

Curso académico 2018/2019

Agradecimientos

Me gustaría dedicar este proyecto a toda la gente que me ha apoyado durante su realización. Sobre todo a mis padres y hermana que siempre están ahí y me ayudan en todo lo que necesito, pues sin ellos no hubiese sido posible conseguirlo.

Agradecer a mi familia todo el interés que han mostrado y como han conseguido que el trabajo fuera más sencillo. También quiero mencionar a mis amigos, los cuales siempre me han dado ánimos e incluso ideas para poder realizar el proyecto.

Por último, y no menos importante, quiero agradecer a mi tutor José María todo el apoyo y sabiduría que me ha dado durante el proceso. Sin su dedicación y paciencia nada hubiera sido posible.

Resumen

La gestión del tráfico rodado es un tema muy complejo, pero con mucha importancia pues tiene grandes repercusiones. Esta gestión típicamente se ha venido realizando mediante una cámara que se centraba únicamente en capturar imágenes y un operario era el encargado de extraer información de estas. En los últimos años se está tratando de automatizar todas aquellas cosas que pueden realizarse sin necesidad de que el ser humano intervenga. Las cámaras son el sensor principal en la gestión del tráfico. Partiendo de esta premisa cada vez se está tendiendo más a diseñar algoritmos capaces de extraer información automáticamente de dichas imágenes.

El objetivo de este trabajo es crear un sistema capaz de extraer información de las imágenes para monitorizar una carretera mediante una única cámara. Este sistema se llama *Smart-Traffic-Sensor* y parte de un sistema previo denominado *Traffic-Sensor*, en el cual se llevaba a cabo la monitorización del tráfico haciendo uso de técnicas clásicas de visión artificial, como sustracción de fondo, tracking, SVM, etc.

Smart-Traffic-Sensor se centra en técnicas modernas como *Deep Learning* para la detección y clasificación de vehículos. La monitorización se fundamenta en criterios de proximidad espacial y Kanade–Lucas–Tomasi (KLT). Para realizar la nueva versión neuronal del sistema ha sido necesario crear una base de datos con suficiente información y recopilar una serie de videos donde poder evaluarlo.

El sistema se ha evaluado experimentalmente con diversos videos en condiciones diferentes con el fin de saber como se comportaría ante posibles cambios meteorológicos o en condiciones de baja calidad de imagen.

Índice general

Índice de figuras	VI
Índice de tablas	VII
1. Introducción	2
1.1. Cámaras en automóviles y su entorno	4
1.2. Las cámaras para monitorización de tráfico rodado	10
1.2.1. Visión computacional en tráfico urbano	12
1.2.2. Monitorización de autopistas basada en visión	15
1.3. Sistemas comerciales basados en visión	16
1.4. Redes Neuronales en Visión Artificial	18
1.5. Objetivos	19
2. Estado del arte	21
2.1. Detección de vehículos	21
2.1.1. Detección de Fondo	22
2.1.2. Técnicas basadas en DeepLearning	24
2.2. Clasificación de vehículos	27
2.2.1. Clasificación basada en características	27
2.2.2. Clasificación basada en modelos 3D	30
2.2.3. Clasificación basada en DeepLearning	31
2.3. Seguimiento de vehículos	32
2.3.1. Seguimiento basado en regiones	33
2.3.2. Seguimiento basado en características	33
2.3.3. Seguimiento basado en modelos	34
2.4. Bases de Datos para la detección de vehículos	34
2.4.1. GRAM Road-Traffic Monitoring	34
2.4.2. BIT-Vehicle Dataset	35
2.4.3. CarND-Vehicle-Detection	36

3. Herramientas utilizadas	38
3.1. DetectionSuite	38
3.2. Entorno TensorFlow	41
3.3. Entorno Keras	42
3.4. Entorno Darknet	43
3.5. Biblioteca OpenCV	44
3.6. Biblioteca Gtkmm	46
4. Aplicación Smart-Traffic-Sensor para Monitorización de Tráfico Rodado	47
4.1. Bases de Datos de Entrenamiento	47
4.2. Diseño de la Aplicación	49
4.3. Detección y Clasificación	51
4.3.1. Entorno TensorFlow y red SSD MobilenetV2	53
4.3.2. Entorno Keras y red SSD VGG-16	56
4.3.2.1. Entorno Darknet y red YOLOv3	57
4.4. Seguimiento de Vehículos	58
4.4.1. Emparejamiento por proximidad	58
4.4.2. Seguimiento por KLT	61
4.4.3. Resumen General del Sistema	64
4.5. Estimación de la Velocidad	64
5. Conclusiones	65
5.1. Conclusiones	65
5.2. Trabajos Futuros	67
Bibliografía	77

Índice de figuras

1.1.	Centro de monitorización de tráfico	2
1.2.	División del sector SIT a nivel de aplicación	4
1.3.	Sistema de reconocimiento automático de matrículas	5
1.4.	Radar de tramo basado en reconocimiento de matrículas	5
1.5.	Sistema de ayuda a bordo del vehículo	6
1.6.	Aparcamiento automático	6
1.7.	Sistema de visión de ojo de pájaro para asistencia en el aparcamiento	7
1.8.	Cámara trasera de BMW para asistencia en el aparcamiento	7
1.9.	Sensores en vehículos autónomos	8
1.10.	Vehículo autónomo participante en el <i>DARPA Grand Challenge</i>	9
1.11.	Vehículo autónomo de Tesla	10
1.12.	Ejemplo de detección y seguimiento de vehículos de [1]	11
1.13.	Control de semáforos en rojo	13
1.14.	Monitorización del tráfico urbano	13
1.15.	Sistema de detección de incidencias en túnel	15
1.16.	Sistema de detección de incidencias en autopistas	15
1.17.	Sistema <i>TraffiCam</i> de FLIR	17
1.18.	Sistema <i>Mesta Fusion</i> de Morpho	17
1.19.	Detección de sustancia blanca en pacientes con insomnio	18
1.20.	Detección de sustancia blanca en pacientes con insomnio	19
2.1.	Fases de R-CNN	25
2.2.	Fases de Faster R-CNN	26
2.3.	Detecciones del sistema de Zezhi Chen and Tim Ellis [2]	29
2.4.	Reconstrucción 3D empleando puntos de fuga	30
2.5.	Clasificación de vehículos basada en modelos 3D construidos mediante el uso de puntos de fuga	30
2.6.	Plantillas 3DHOG para la clasificación de vehículos	31
2.7.	Reconstrucción del histograma 3DHOG	31
2.8.	Arquitectura AlexNet	32

2.9.	Imágenes de ejemplo del dataset GRAM Road-Traffic Monitoring	35
2.10.	Imágenes de ejemplo del dataset BIT-Vehicle	36
2.11.	Imágenes de ejemplo del dataset 2 de CarND-Vehicle-Detection	37
3.1.	Ejemplo de IOU	39
3.2.	Fórmula IOU	40
3.3.	Proceso de Yolo	43
3.4.	Funciones de OpenCV	45
4.1.	Zonas de entrada y seguimiento	49
4.2.	Zona Evaluación	50
4.3.	Zonas identificadas en la zona de Evaluación	52
4.4.	Red SSD Mobilenet V2	53
4.5.	Red SSD	56
4.6.	Red VGG-16	57
4.7.	Arquitectura YOLO	58
4.8.	Evolución del área alrededor del vehículo	60
4.9.	Elipse asociada a los vehículos	60
4.10.	Seguimiento con proximidad espacial	61
4.11.	KLT Piramidal	63

Índice de tablas

4.1. Muestras de la Base de Datos	48
4.2. Imágenes de la Base de Datos	48
5.1. Resultados de Y. Abdullah, G. Mehmet, A. Iman and B. Erkan [3] . . .	66
5.2. Resultados de Y. Abdullah, G. Mehmet, A. Iman and B. Erkan [3] . . .	67

Acrónimos

CNN Convolutional Neural Network.

CNTK The Microsoft Cognitive Toolkit.

COCO Common Objects in Context.

CUDA Compute Unified Device Architecture.

EM Expectation Maximization.

EOH (Edge Orientation Histogram.

FPS Frames Per Second.

GMM Gaussian mixture models.

GRAM-RTM GRAM Road-Traffic Monitoring.

HDF5 Hierarchichal Data Format version 5.

HOG Histogram of Oriented Gradients.

IA Inteligencia Artificial.

ICE Internet Communications Engine.

IOU Interseccion Over Union.

IPHOG Intensity-based on a Pyramid of Histogram of Gradient Orientations.

KAA Kernel Auto Associator.

KLT Kanade–Lucas–Tomasi.

mAP mean Average Precision.

mAR mean Average Recall.

CAPÍTULO 0. INTRODUCCIÓN

MBF Measurement Based Features.

MEI Motion Energy Images.

MOG Mixture of Gaussian.

NMS Non-Maximum Suppression.

OpenCV Open Source Computer Vision Library.

R-CNN Region-based Convolutional Neural Network.

RNA Redes Neuronales Artificiales.

SAD Sum of Absolute Differences.

SIFT Scale-Invariant Feature Transform.

SSD Single Shot Detector.

SVM Support Vector Machine.

TFM Trabajo de Fin de Máster.

VA Visión Artificial.

XML Extensible Markup Language.

YOLO You Only Look Once.

Capítulo 1

Introducción

Debido al crecimiento en la población se ha visto incrementada la cantidad de vehículos que se encuentran en circulación. Este incremento en la densidad de vehículos ha afectado en el tráfico y en la contaminación. Por ello se han ido buscando formas de mejorar la seguridad vial y el rendimiento en las carreteras. Las nuevas tecnologías son capaces de ofrecer mucha información para mejorar el tráfico. La aplicación de sistemas avanzados de información y comunicación a las infraestructuras de transporte y a los vehículos para mejorar la seguridad vial, la eficiencia y el rendimiento de las carreteras se denomina Sistemas inteligentes de transporte (SIT). Este área está en continuo desarrollo y pretende dotar a los vehículos de inteligencia para mejorar nuestra seguridad y monitorizar las redes de transporte para detectar posibles incidencias y mejorar el tráfico.



Figura 1.1: Centro de monitorización de tráfico

Los sistemas tradicionales de monitorización ofrecen una información limitada, pues normalmente es un humano el que analiza toda la información que le aportan las cámaras y con ello toma las decisiones. Gracias a los últimos avances en visión artificial muchas de las tareas que realizaba el humano se han podido automatizar. Con la visión artificial somos

CAPÍTULO 1. INTRODUCCIÓN

capaces de procesar todas las imágenes que recogen las cámaras y extraer información de ellas, como por ejemplo la cantidad de tráfico que hay, las condiciones meteorológicas que tenemos, la existencia de incidencias, etc.

Los principales sectores de los SIT son:

1. Gestión avanzada del transporte
2. Gestión avanzada del transporte público
3. Sistemas de cobro automático

El primer sector hace referencia a la gestión de carreteras a nivel global. Sus funciones principales son agilizar el tráfico, mejorar la movilidad, optimizar el uso de las infraestructuras y mejorar la seguridad de las redes de transporte. Para conseguir todo esto se emplea como sensor principal las cámaras. Con dichas cámaras se obtienen imágenes en todo momento, las cuales son procesadas y analizadas por seres humanos o automáticamente mediante algoritmos de visión artificial.

El segundo sector tiene el mismo fin que el primer sector pero limitado a sistemas de transporte público. Entre sus funciones se encuentra gestionar de forma eficaz y optimizada las redes de transporte público, e informar a los ciudadanos acerca de las distintas alternativas de transporte disponibles así como sus horarios o sus posibles incidencias en tiempo real. Este sector también se encarga de todo lo referente a los sistemas de cobro y el manejo de billetes en el transporte. Su objetivo es facilitar la integración y unificación de los sistemas de cobro para facilitar la creación de billetes multimodales y tarjetas de transporte subvencionadas por el estado.

El último sector (sector de cobro automático) se encarga de todos los sistema electrónicos de gestión de cuotas. La gestión de cobros automáticos en autopista con sistemas de telepeaje se basa en el empleo de sistemas inalámbricos de comunicación entre el sistema de gestión de cobro y el vehículo. En estos sistemas el vehículo debe disponer de un dispositivo, el cual permite identificarlos de manera segura y gestionar su cuota sin necesidad de que el vehículo se detenga en el telepeaje. Con esto se consigue reducir el atasco en los peajes.

Aparte de la división a nivel sectorial de los SIT explicada, existe una división a nivel de aplicaciones. Esto puede verse en la Figura 1.2.

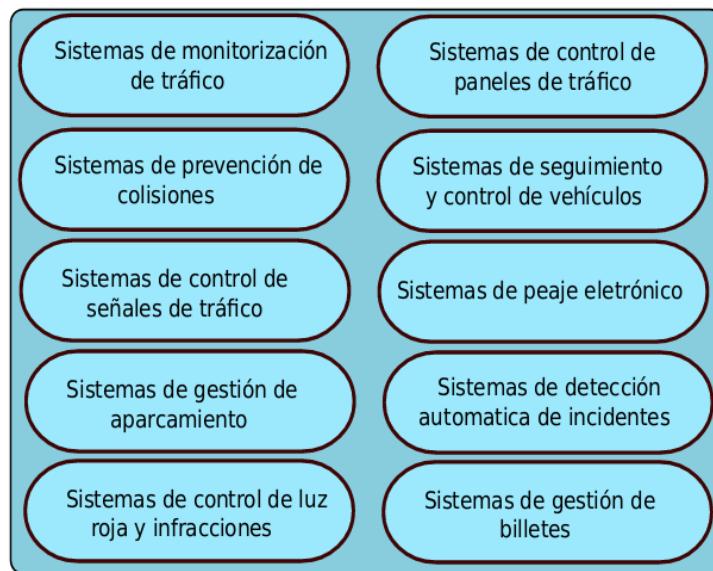


Figura 1.2: División del sector SIT a nivel de aplicación

1.1. Cámaras en automóviles y su entorno

Si pensamos en una ciudad inteligente lo primero que nos viene a la cabeza son cámaras. Actualmente las cámaras se emplean en muchos ámbitos debido a la gran calidad que ofrecen, lo económicas que son y su reducido tamaño. Una de las aplicaciones pioneras donde la visión artificial ha demostrado ser una solución práctica frente a otras alternativas es la detección de matrículas. Este caso en concreto se usa en muchas puertas de acceso a aparcamientos, pues ha demostrado que tiene una gran fiabilidad. Típicamente se trata de escenarios muy controlados, pues conocemos la iluminación del lugar, la posición que toman los vehículos, etc.



Figura 1.3: Sistema de reconocimiento automático de matrículas

Otra aplicación de las cámaras son los radares de tramo. En este caso se pretende calcular la velocidad media de cada vehículo haciendo uso del reconocimiento de matrículas. Las cámaras suelen situarse en los extremos de un túnel, ya que la trayectoria del vehículo está bajo control.



Figura 1.4: Radar de tramo basado en reconocimiento de matrículas

Otro campo en el que cada vez tienen mayor relevancia las cámaras es en seguridad vial. Hoy en día hay varios modelos de coches capaces de detectar señales de tráfico de manera automática. De esta forma el vehículo puede avisar al conductor del exceso de velocidad, de la dirección de la próxima curva, etc. Este tipo de sistemas se encuentran

CAPÍTULO 1. INTRODUCCIÓN

incorporados en vehículos de marcas comerciales como BMW 7-series, Ford Focus, Toyota, Opel Insignia, etc.



Figura 1.5: Sistema de ayuda a bordo del vehículo

Disponer de cámaras en los vehículos ha hecho posible aumentar la seguridad, pues aportan mucha información. Actualmente existen modelos de vehículos que nos avisan de la presencia de peatones e incluso poseen mecanismos de frenado automático evitando posibles atropellos.

Otra aplicación de las cámaras muy presente en los vehículos es el asistente para el aparcamiento. En esta aplicación las cámaras pueden aportar imágenes acerca de los alrededores de nuestro vehículo, ofreciéndole información acerca de cómo debemos aparcar, e incluso forman parte de sistemas multisensoriales para aparcar automáticamente.

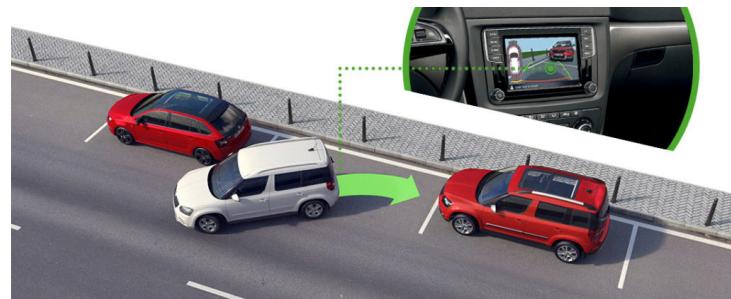


Figura 1.6: Aparcamiento automático

Un ejemplo de asistencia en el aparcamiento es el sistema de ojo de pájaro de Nissan. Dicho sistema ofrece una vista aérea simulada de la escena del aparcamiento. En ella se incluye el vehículo y sus alrededores, ofreciéndole al conductor gran información acerca

CAPÍTULO 1. INTRODUCCIÓN

de la situación. Con lo que podrá realizar la maniobra de forma más sencilla y segura. Para conseguir esto, el vehículo dispone de 4 cámaras, las cuales emplea para generar la imagen cenital compuesta. A parte de esta simulación, el conductor puede usar la cámara trasera para obtener más detalles de la escena.

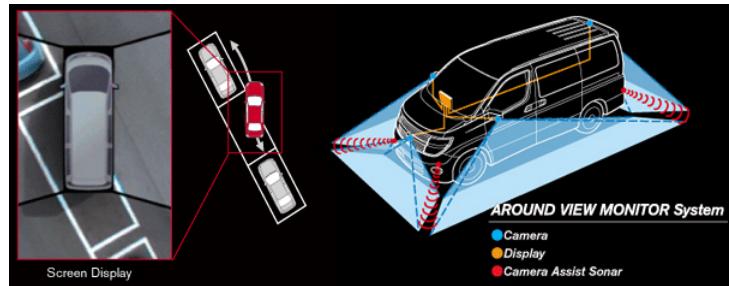


Figura 1.7: Sistema de visión de ojo de pájaro para asistencia en el aparcamiento

BMW tiene un sistema un poco más evolucionado, pues aparte del sistema de Nissan, posee una cámara trasera con sensores que miden las distancias con los obstáculos. En la imagen que ofrece proyecta una serie de líneas que ayudan en la orientación del vehículo durante la maniobra de aparcamiento. Estas imágenes son enriquecidas con marcas 3D que se basan en un código de color para marcar la distancia con los obstáculos. Además de todo esto, el sistema proporciona al conductor un mapa del vehículo y los obstáculos que le rodean en todo momento.



Figura 1.8: Cámara trasera de BMW para asistencia en el aparcamiento

Hoy en día uno de los campos en continua evolución es el de los coches autónomos, pues cada día hay más empresas interesadas en ello. Pero este tema no es tan reciente, ya que en 1950 ya se trataba de crear coches autónomos. Y desde entonces se han conseguido continuos avances en su mayor medida destinados a aportar a los vehículos sistemas para navegar de forma autónoma.

CAPÍTULO 1. INTRODUCCIÓN

Los coches autónomos disponen de un radar en la parte frontal para detectar vehículos próximos. Este sensor se emplea para mantener la distancia de seguridad con el vehículo que se encuentra delante y para posibles frenadas de emergencia si fueran necesarias. En las ruedas traseras tienen un sensor ultrasonido capaz de detectar obstáculos muy cercanos al vehículo, permitiendo con ello realizar maniobras muy precisas. Este sensor es muy práctico en el aparcamiento autónomo, pues ofrece información muy precisa en todo momento acerca de los obstáculos que se encuentren en la parte trasera. En la parte superior del vehículo se dispone de una antena GPS, una cámara Lidar y una cámara frontal. La antena GPS permite que el vehículo pueda localizarse con gran precisión en exteriores. La cámara Lidar (Light detection and ranging) realiza un barrido continuo de 360° para construir un mapa 3D de los alrededores del vehículo. La cámara frontal analiza todo lo que el vehículo tenga en frente, como por ejemplo señales de tráfico, peatones, otros vehículos, etc. A parte de todo lo comentado por supuesto contienen un ordenador a bordo que analiza la información captada por todos los sensores y en función a ella toma las decisiones que correspondan. Todos estos sensores pueden verse en la Figura 1.9.

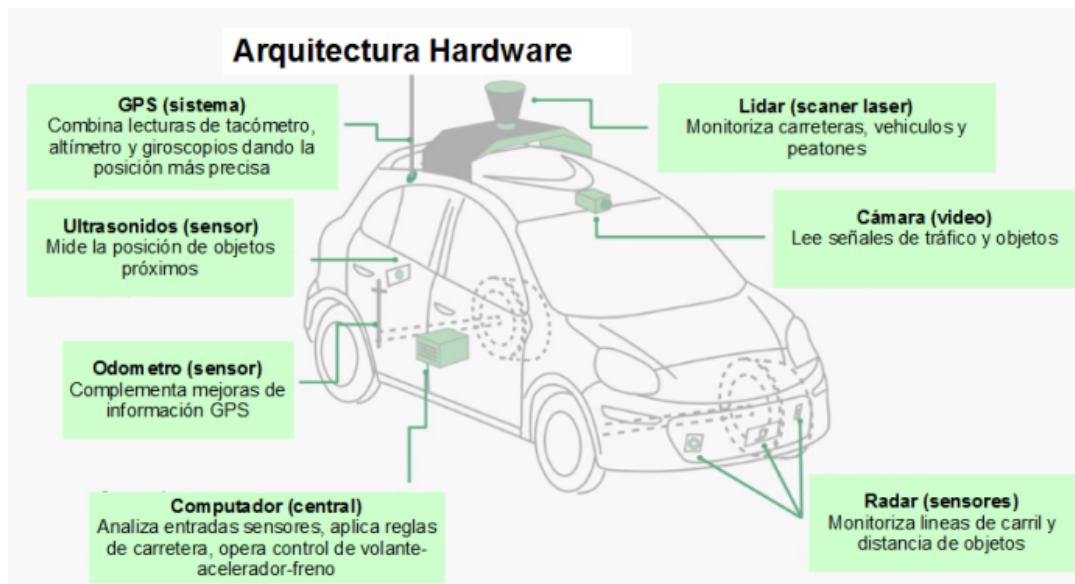


Figura 1.9: Sensores en vehículos autónomos

Si hablamos de conducción autónoma no nos podemos olvidar de mencionar al DARPA Grand Challenge. Fue una competición donde vehículos autónomos trataban de completar un circuito en el desierto en un tiempo determinado. En ella podía inscribirse cualquier entidad ya sea privada o pública. Esta competición fue creada por la agencia de

CAPÍTULO 1. INTRODUCCIÓN

investigación DARPA con el objetivo de incentivar la creación y el desarrollo de vehículos autónomos capaces de llevar a cabo misiones preplanificadas. Con ello se pretendía poder emplear esta tecnología en misiones de exploración así como para aplicaciones militares.

La agencia DARPA también organiza la competición DARPA Urban Challenge. Esta competición tiene la misma dinámica que la mencionada anteriormente pero se desarrolla en un entorno urbano, el cual consta de 96km los cuales deben completarse en menos de 6 horas. Durante el trayecto los vehículos tienen que interactuar con otros vehículos autónomos o vehículos ocupados por conductores profesionales.



Figura 1.10: Vehículo autónomo participante en el *DARPA Grand Challenge*

A pesar de todas las empresas implicadas en este desarrollo de vehículos autónomos las más famosas en este campo son Google, Tesla. Ambas tienen sistemas capaces de realizar la conducción de forma completamente autónoma aunque se necesita de la supervisión de un humano capaz de intervenir en caso de ser necesario.



Figura 1.11: Vehículo autónomo de Tesla

1.2. Las cámaras para monitorización de tráfico rodado

En comparación con otras disciplinas, la aplicación de la visión computacional en el análisis del tráfico rodado es un campo de estudio muy joven. Las primeras aplicaciones de este tipo fueron presentadas por Onoe M., Ohba K. [4] y Hilbert [5]. Pero hasta la década de los 80 no hubo una actividad constante de publicaciones. En este periodo ya podemos encontrar referencias a aplicaciones basadas en visión artificial y orientadas al análisis del tráfico de vehículos. Por ejemplo Hoose, N [6] en 1989 presentó una técnica para calcular de manera automática la longitud de la cola formada por vehículos parados o circulando a una velocidad muy reducida. Ese año J.M Blosseville, C. Krafft, F. Lenior, V. Motyka, S. Beucher [7] presentaron el sistema TITAN, el cual es capaz de analizar escenas de entre 100 hasta 300 metros de longitud, día y noche. Con ello extrae parámetros tales como el flujo de vehículos, la velocidad y la longitud de la cola en atascos, todo esto con una velocidad de procesamiento de 4 imágenes por segundo. Las dificultades más importantes de este trabajo son las luces de noche y los techos, capós y sombras frontales de día.

En 1989 Versavel, J. ;Lemaire, F. ; Van der Stede, D. [8] también presentó el sistema CCATS, el cual obtiene parámetros del tráfico como la ocupación de los carriles, el número de vehículos y la velocidad media de éstos. Además puede detectar anomalías en el flujo de vehículos como atascos o largas colas y alertar acerca de ello. Este sistema fue instalado en Bélgica para mejorar el tráfico.

Hasta finales de los 80 los trabajos se centraron en un macro análisis del tráfico para

CAPÍTULO 1. INTRODUCCIÓN

extraer datos relativamente simples. A partir de los 90 esto va a cambiar pues aumentará la investigación en este sector y se empezarán a realizar análisis más detallados de las escenas basándose en las características visuales de los vehículos. Es entonces cuando se empieza a usar plantillas 3D para la clasificación y seguimiento de vehículos. Baker, K.D Sullivan, G.D. [9] se dedicaron a analizar la viabilidad del seguimiento del tráfico basándose en modelos 3D. Para este seguimiento de tráfico han empleado reconocimiento y estimación de posición en secuencias de imágenes. En esa época el reconocimiento y estimación de posición estaba pensado para una sola imagen, por lo que fueron pioneros al aplicarlo en secuencias de imágenes. En su trabajo disponían de información a priori acerca de la escena 3D, la cual obtenían mediante una cámara calibrada. A pesar de no funcionar en tiempo real este trabajo fue el que abrió las puertas hacia nuevos estudios relacionados con el seguimiento de vehículos.

Koller, D., Weber, J., Malik, J. [1] presentaron un trabajo en el cual describían un sistema basado en el seguimiento de vehículos haciendo especial importancia en las occlusiones, uno de los grandes problemas en los sistemas de análisis de tráfico. En la Figura 1.12 podemos ver un ejemplo de su trabajo.

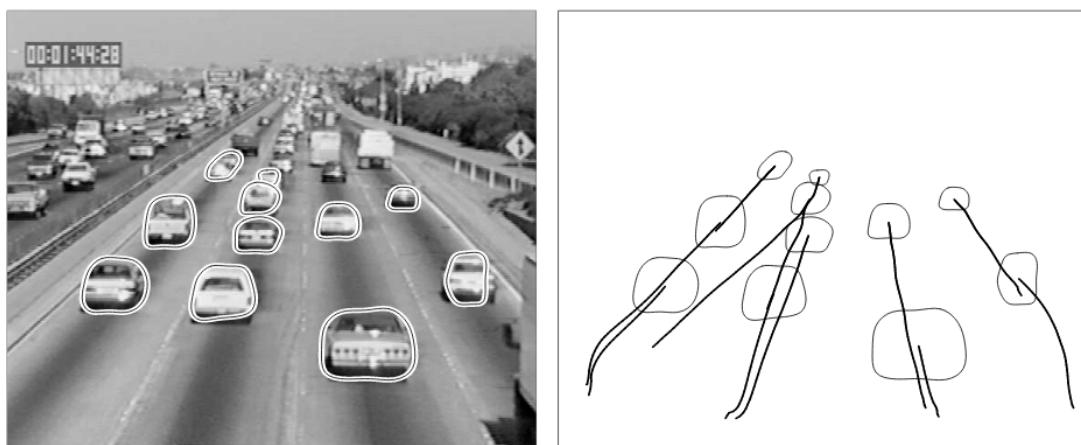


Figura 1.12: Ejemplo de detección y seguimiento de vehículos de [1]

G.D. Sullivan, K.D. Baker, A.D. Worral, C.I. Attwood, P.M. Remagnino [10] publicaron un sistema para la clasificación de vehículos empleando una combinación de plantillas en 1-D y 2-D. Las plantillas 1-D se generaban sobre modelos de vehículos y las 2-D se empleaban para la verificación y aceptación de las hipótesis generadas en la primera fase del algoritmo de clasificación. Coifman et al. [11] presentaron un algoritmo capaz de seguir un conjunto de características visuales de los vehículos (en lugar del vehículo completo)

con lo cual pretende ser más robusto ante oclusiones.

Las técnicas que se han ido publicando en las últimas décadas se presentan en dos escenarios (tráfico urbano y tráfico en autopistas). A continuación se explicará las situaciones que se encuentran en ambos escenarios.

1.2.1. Visión computacional en tráfico urbano

En el análisis de tráfico urbano se pretende aplicar las técnicas de visión computacional en ciudades o entornos urbanos en general. En este caso la visión computacional se emplea para asegurar la aplicación de las normas de tráfico, para obtener información acerca del flujo de tráfico o para detectar posibles incidencias. El entorno urbano es un entorno muy complejo, pues existen demasiadas variables involucradas. Podemos tener peatones, ciclistas, edificios, señales de tráfico, árboles, otros vehículos, etc. Esto hace que sea más probable tener oclusiones en la imagen.

Una aplicación muy habitual en entornos urbanos es la detección de conductores que no respetan los semáforos en rojo. Para ello se hace uso de cámaras que se encuentran conectadas a las luces del semáforo, y cada vez que éste se pone en rojo las cámaras se activan. Todo vehículo que sobrepasa la línea blanca una vez que el semáforo está en rojo quedará fotografiado. Pero esto no siempre se tiene totalmente en cuenta, pues en muchas legislaciones es necesaria una prueba irrefutable de que el vehículo se ha saltado el semáforo. Esto se debe a que en muchos casos cuando un semáforo está en ambar los coches aceleran, corriendo el riesgo de pasar justo cuando el semáforo se ponga en rojo. Con el fin de evitar estos problemas, los sistemas han ido avanzando. Actualmente se graban toda la escena para poder asegurarse de si existe una infracción o no. La cámara se sitúa antes del semáforo para poder ver claramente a los vehículos infractores. Además se les ha incorporado un mecanismo para medir la velocidad de los vehículos que pasan y así poder ver si tienen alta probabilidad de saltarse los semáforos. Si superan cierta velocidad se considera que tienen una alta probabilidad de cometer una infracción y es entonces cuando la cámara se activa para grabarlo.



Figura 1.13: Control de semáforos en rojo

En el tráfico interurbano una aplicación muy común es la detección de infracciones. Los centros de monitorización del tráfico disponen de muchas cámaras en las carreteras, pero el personal dedicado a revisar las imágenes que obtienen es bastante reducido, por lo que surge la necesidad de automatizar este proceso. A esta automatización de la detección de incidencias se le llama AID y gracias a ella los trabajadores dedicados a la monitorización del tráfico solo tienen que revisar las imágenes en las cuales las cámaras han detectado una incidencia. El hecho de automatizar este proceso hace que el tiempo de intervención se vea reducido, pues son capaces de detectar las incidencias en menor tiempo, minimizando el tiempo de respuesta de los servicios sanitarios. Con esta información pueden actualizarse los paneles informativos, para avisar al resto de vehículos de la existencia de un accidente.



Figura 1.14: Monitorización del tráfico urbano

CAPÍTULO 1. INTRODUCCIÓN

Vermeulen [12] combina la información visual con información obtenida por una cámara térmica para detectar incidentes. Con esto consigue un sistema muy robusto ante las diferentes condiciones meteorológicas. Este sistema fue instalado en el puente de *Rion* en Grecia. Chang et al [13] presentó un sistema basado en la detección de matrículas para la identificación de incidencias. En este caso emplea la información del tiempo de viaje del vehículo para inferir incidencias en su trayectoria.

Otro tema en creciente desarrollo es el análisis del comportamiento de los vehículos en rotundas o bifurcaciones. A la hora de realizar modificaciones en las infraestructuras viales se realizan estudios acerca del flujo de vehículos que circulan por las redes de transporte, para ello es muy útil conocer el comportamiento de los vehículos. Nateghinia and Moradi [14] realizó un sistema capaz de seguir los vehículos en intersecciones y resolver el problema de las occlusiones. Para realizar las detecciones modelan cada píxel como una distribución gaussiana y lo combinan con el modelado dinámico de textura. Shirazi and Morris [15] presentaron un sistema un poco más evolucionado, pues a parte de seguir y contar los vehículos en cada intersección, era capaz de estimar la capacidad y el tiempo de espera en la intersección y reconstruir la trayectoria de los vehículos.

Finalmente, no hay que olvidarse de los túneles, los cuales juegan un papel importante dentro del tráfico urbano. De hecho en la M-30 en Madrid tenemos una longitud de 43 km de túneles, con el fin de reducir el flujo de tráfico sobre la superficie. Debido al gran uso de los túneles y la dificultad que existe para acceder a ellos en caso de accidentes, es necesario monitorizarlos. El uso de cámaras en los túneles hace que se pueda identificar la existencia de incidencias dentro de ellos, para actuar en el menor tiempo posible. En este caso una actuación rápida es esencial para evitar segundos accidentes o catástrofes en caso de incendios.



Figura 1.15: Sistema de detección de incidencias en túnel

1.2.2. Monitorización de autopistas basada en visión

En este caso el análisis del tráfico se realiza en autopistas. Con ello se pretende obtener información acerca de la velocidad de los vehículos, el flujo de tráfico, la existencia de incidencias, etc. Este entorno es más sencillo que el comentado en el Apartado 1.2.1, ya que no hay que controlar tantas variables (peatones, edificios , etc), únicamente tendremos vehículos de diferentes tipos.



Figura 1.16: Sistema de detección de incidencias en autopistas

La mayoría de los sistemas mencionados en el caso de entornos urbanos se emplean en las autopistas, ya que las incidencias que ocurren son similares. La principal diferencia entre ambos escenarios es la velocidad de los vehículos. En el tráfico urbano el límite de velocidad es bajo, pero en las autopistas es mucho más elevado y depende de cada país. En España el límite está en 120km/h pero en Alemania la velocidad no está limitada. Esto se debe tener en cuenta a la hora de realizar el sistema de monitorización.

1.3. Sistemas comerciales basados en visión

Antiguamente la visión computacional solo se desarrollaba en el ámbito de la investigación pero actualmente se ha visto extendida hasta un ámbito comercial. Actualmente en el mercado hay numerosos sistemas basados en visión. Gracias a su reducido coste y su gran fiabilidad los sistemas basados en visión se han convertido en una alternativa perfecta a los sistemas clásicos de detección.

Desde los años 80 el empleo de la tecnología en los sistemas inteligentes de transporte ha ido creciendo. Esto se debe a que es un sector muy importante en los países en vías de desarrollo y en los países desarrollados. Algunas de las empresas que desarrollan este tipo de sistemas son: Flir (EEUU), Siemens (Alemania), Indra (España), Kapsch (Austria), Q-Free (Noruega), Thales (Francia), Sigtec (Austria).

Siemens es uno de los mayores proveedores de sistemas de control de tráfico a nivel mundial. Su familia de sistemas *SitTraffic* ofrece un amplio abanico de funcionalidades.

FLIR es una empresa muy activa en este sector, pues ofrece sistemas con diversas funciones (detección automática de atascos, presencia de vehículos en las intersecciones, detección de peatones , etc). Su sistema combina cámaras visuales y cámaras térmicas que le permiten regular las luces de tráfico. La serie de productos *TrafiCam* realiza la detección y seguimiento de vehículos en intersecciones de forma automática; y permite posicionar y verificar con exactitud las zonas de detección de presencia de vehículos. Además este sistema mide la longitud de las colas que se forman en los atascos.



Figura 1.17: Sistema *TraffiCam* de FLIR

La empresa Morpho ha desarrollado un sistema basado en visión que pretende sustituir a los radares tradicionales. Se trata de su sistema *Mesta Fusion*, el cual es capaz de detectar coches que circulen hasta a 300 km/h, puede controlar ocho carriles al mismo tiempo, supervisar 32 vehículos a la vez y discriminar entre ellos según sea un turismo, una moto, una furgoneta o un camión o autobús. Además es capaz de identificar casi cualquier acción indebida. Todo eso lo hace un sistema perfecto en temas de monitorización de tráfico. Este sistema ya está operativo en Francia y Dubai.

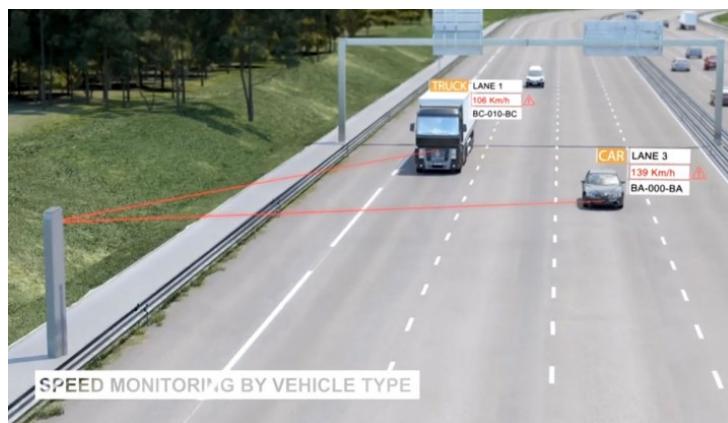


Figura 1.18: Sistema *Mesta Fusion* de Morpho

1.4. Redes Neuronales en Visión Artificial

Las Redes Neuronales Artificiales (RNA) son un modelo matemático que pretende asemejarse al comportamiento biológico de las neuronas. Su objetivo principal es poder aprender al igual que lo hacen los seres humanos, para ello siguen una estructura jerárquica similar.

En los últimos años han cobrado gran relevancia debido a su capacidad para aprender datos. Esto es aplicable a la hora de detectar objetos. Pues son capaces de aprender información acerca de sus características y en función a ellas identificar objetos. Por ello cada vez son más los sistemas que se basan en este tipo de técnicas.

En el campo de la medicina médica cada vez se hace más uso del *Deep Learning*. Antiguamente era un médico quien examinaba las imágenes (resonancias, radiografías, etc) y evaluaba que podía estar ocurriendo. Actualmente existen aplicaciones informáticas capaces de detectar tumores cerebrales u otras anomalías en las imágenes. En la Figura 1.19 se puede ver como se detecta sustancia blanca en pacientes con insomnio gracias al uso de redes neuronales.

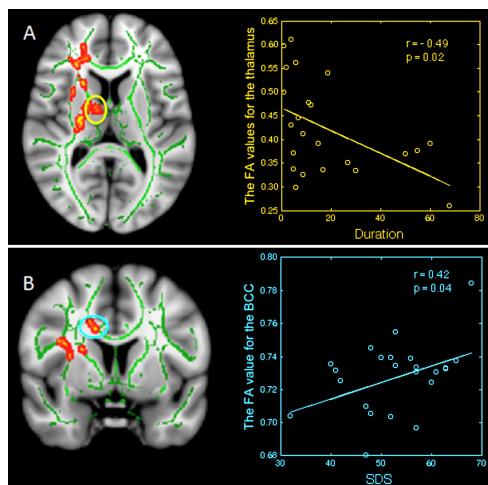


Figura 1.19: Detección de sustancia blanca en pacientes con insomnio

En el sector automovilístico las redes neuronales han tomado el control. Prácticamente todos los últimos vehículos desarrollados tienen algún sistema que emplea redes neuronales. Ya son muchos los vehículos que poseen sistemas de aparcamiento automático, detección de señales, detección de peatones, etc. Todo ello desarrollado en base a redes neuronales. Incluso se está dando el salto a sistemas completamente autónomos que se

fundamentena en su totalidad en redes neuronales.

Otra aplicación muy extendida actualmente es la monitorización de vehículos para tratar de controlar y mejorar el tráfico. Automatizando así el control de las carreteras, sin necesidad de que un operario revise a mano todos los vídeos. En esta disciplina se realizan sistemas que se encargan de la detección de matrículas (muy empleado también en los garajes), el control de la velocidad, la detección de accidentes o situaciones anómalas, etc. En la Figura 1.20 se puede ver en funcionamiento el sistema de un vehículo que detecta otros vehículos y peatones, y estima la distancia a la que se encuentran de él.

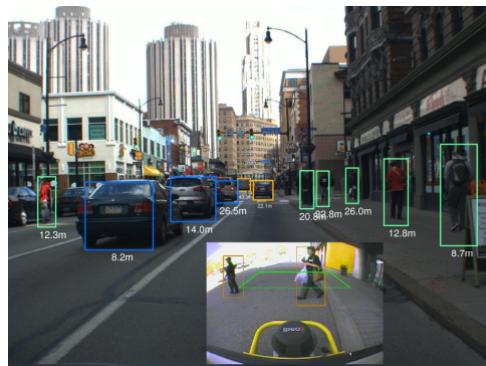


Figura 1.20: Detección de sustancia blanca en pacientes con insomnio

Actualmente las RNA han tomado mucha relevancia en el mundo de la Visión Artificial (VA) debido a sus grandes resultados. Pues se ha visto que son capaces de aprender gran cantidad de características dando mayor robustez a los sistemas de visión artificial.

1.5. Objetivos

Este Trabajo de Fin de Máster (TFM) se encuadra en la monitorización visual de vehículos rodantes mediante el uso de una cámara. El objetivo principal de este proyecto es obtener un sistema capaz de detectar, clasificar y realizar un seguimiento de vehículos rodantes en tiempo real. Para ello se ha partido de un sistema inicial realizado por Redouane Kachach [16] (*Traffic-Monitor* [17]) en su tesis doctoral. Dicho sistema se basa en técnicas clásicas de visión. El planteamiento en este TFM es mejorar sus resultados con el uso de técnicas de *Deep Learning*. Este objetivo principal lo hemos articulado en cuatro subobjetivos concretos:

- La detección se basa en identificar la posición de los vehículos en la imagen. Al

CAPÍTULO 1. INTRODUCCIÓN

hacer uso de *Deep Learning* la detección y clasificación de vehículos van de la mano. En este trabajo se evaluarán diferentes librerías relacionadas con el *Deep Learning*, tales como *TensorFlow*, *Keras* y *Darknet*, para incorporar a la aplicación la que mejores resultados ofrezca.

- Se pretende clasificar los vehículos en función de 7 clases: Motocicletas, Coches, Furgonetas, Autobuses, Camiones Pequeños, Camiones y Camiones Cisterna.
- En cuanto al seguimiento, el subobjetivo es tener la capacidad de realizar el tracking de cada vehículo durante todo el recorrido y aumentar la robustez del sistema ante condiciones meteorológicas adversas o de calidad de cámara pobre. Hay que decir que en la tesis de Redouane Kachach [16] no se tuvieron en cuenta secuencias de video con diferentes tipos de condiciones meteorológicas, pero en este caso se pretende que el sistema sea capaz de funcionar con diferentes condiciones.
- Para conseguir todos los subobjetivos mencionados es necesario recopilar una amplia base de datos que nos ofrezca datos de vehículos en diferentes condiciones meteorológicas, y con menor o mayor calidad de imagen, para tratar de conseguir un sistema lo más robusto posible.

Además de alcanzar los objetivos el sistema debe cumplir los siguientes requisitos:

1. El sistema tiene que emplear como sensor una cámara.
2. El sistema debe funcionar en tiempo real.
3. Los algoritmos están preparados para funcionar de día. El sistema no se ha desarrollado para que sea capaz de funcionar por la noche.

Capítulo 2

Estado del arte

En este capítulo se revisará la bibliografía más relevante relacionada con la monitoreo del tráfico rodado, obteniendo así información acerca de las diferentes técnicas propuestas. Nos centraremos en las técnicas propuestas para la detección, clasificación y seguimiento de vehículos en las cuales se haga uso únicamente de una cámara como sensor. La detección consiste en localizar la posición de cada vehículo en la imagen. La clasificación trata de identificar a que clase pertenece cada detección. Y el seguimiento consiste en asociar los vehículos en las sucesivas secuencias de video.

En los últimos años el precio de las cámaras se ha visto reducido y la potencia de cómputo de nuestros dispositivos ha aumentado, favoreciendo al desarrollo de sistemas de análisis de tráfico. Debido a esto, se trata de un área en continuo desarrollo desde los años 90, en el cual se pretende dar una solución en tiempo real.

A continuación veremos las soluciones que plantean diferentes autores para cada punto. Hay que decir que en muchas ocasiones la detección y la clasificación se hacen conjuntamente. No obstante vamos a comentar por separado cada fase.

2.1. Detección de vehículos

La detección de vehículos trata de identificar donde se localizan los vehículos en los fotogramas. En la literatura hay numerosas técnicas que han sido planteadas para esta función, las cuales van a ser comentadas a continuación.

2.1.1. Detección de Fondo

Una técnica muy empleada en este problema es la sustracción del fondo. Se trata de restar la imagen del fondo de las sucesivas imágenes, con el fin de quedarnos con los objetos que se encuentran en movimiento, que en este caso en concreto serán los vehículos. S.I. Arroyo, F. Safar and D. Oliva [18] se basan en la diferencia entre el fotograma actual y la imagen referencia (imagen de fondo). Esta imagen referencia debe ajustarse a las condiciones de luminosidad en el tiempo.

Otra técnica muy parecida a la sustracción de fondo es la diferencia absoluta (Sum of Absolute Differences (SAD)) entre dos secuencias. A.F. Granados and J.I. Marin .H [19] presentan una técnica basada en la diferencia absoluta (SAD) entre dos fotogramas consecutivos. Para ello aplican filtrado homomórfico con el fin de reducir el efecto de los cambios de iluminación. Tras esto realizan la diferencia absoluta (SAD), umbralizan y segmentan los objetos en movimiento. J. Portillo, G. Sánchez, J. Olivares and H. Pérez [20] también propusieron un método en el que se hacía uso de la SAD y complementariamente se realizaba un análisis de bordes en la región considerada en movimiento.

En la vida real tenemos situaciones más complejas, pues los cambios de iluminación y la aparición de objetos en la escena (por ejemplo ramas de los árboles, personas, etc) es muy probable. Por tanto, necesitamos un método que sea capaz de funcionar correctamente a pesar de estos problemas.

Mixture of Gaussian (MOG) es una técnica que aplicaron C.Stauffer and W.E. Grimson [21] por primera vez al problema de la sustracción de fondo. Esta técnica se basa en el empleo de varias gaussianas para modelar cada píxel, permitiendo modelar varios estados del fondo a un mismo píxel. Es decir, esta técnica permite modelar un píxel cuyo valor cambia constantemente debido a movimientos periódicos. La pertenencia de cada nuevo píxel al fondo es evaluada contra las distintas gaussianas que lo forman. Si el valor de un píxel está en un rango de 2.5 la desviación estándar de la gaussiana, se considera que pertenece a dicha gaussiana. El nuevo píxel será clasificado como fondo si pertenece a alguna de estas gaussianas y los parámetros serán actualizados con el nuevo valor.

La mezcla de gaussianas es muy utilizada en detecciones de fondo, esto se puede ver reflejado en la cantidad de trabajos que hacen uso de esta técnica. De hecho el trabajo del que se ha partido en este caso [16] hace uso de una versión mejorada de MOG propuesta por Zoran Zivkovic [22]. El avance de este método es que para cada píxel se puede adaptar

el número de gaussianas que se van a emplear.

P. Barcellos, C. Bouvié, F.L. Escouto and J. Scharcanski [23] propusieron un método para la detección de vehículos que se basaba en una combinación de *Gaussian mixture models (GMM)* y *Motion Energy Images (MEI)* [24]. MEI es la imagen de energía de movimiento e indica en cuales píxeles se detectó movimiento a lo largo de una secuencia de fotogramas. Esta técnica se incluye para introducir información temporal del primer plano, ya que gracias a ello tendremos una máscara binaria con los píxeles del primer plano que han sufrido movimiento.

Xia et al. [25] combinaron GMM y Expectation Maximization (EM). EM comienza prediciendo los parámetros de las distribuciones y los usa para calcular las probabilidades de que cada objeto pertenezca a una clase. Esas probabilidades se usan para re-estimar los parámetros de las probabilidades hasta que consigamos que converjan.

Buch et al. [26] presentaron un sistema que combina puntos de interés 3D y Histogram of Oriented Gradients (HOG) para detectar el fondo presentando así 3DHOG.

Bjorn Johansson, Johan Wiklund, Per-Erik Forssén and Gösta Granlund [27] emplean el método estadístico de J.Wood [28] para identificar si un píxel pertenece al fondo o al primer plano. El método es una modificación del conocido método de sustracción de fondo de C.Stauffer and W.E. Grimson [21], con una regla de actualización algo diferente y un límite de regularización más bajo para las desviaciones estándar de Gauss. Principalmente lo que se hace es usar un modelo de mezcla de gaussianas en cada píxel para estimar la distribución de color a lo largo del tiempo, detectándose como píxeles de primer plano aquellos cuyo color sea improbable que pertenezca a la distribución. Además los píxeles de primer plano pueden ser clasificados como sombras. Si el color de un píxel se encuentra en una región cilíndrica entre el negro (el origen) y cualquiera de los colores centrales de las gaussianas de fondo se considerará sombra.

Otra técnica empleada a la hora de detectar el fondo es hacer uso de los denominados *codebooks*. Originalmente esta clase de técnicas fueron empleadas en la clasificación de texto. A la hora de clasificar texto es muy importante disponer de un diccionario de palabras que se ajuste al contenido que tendrá dicho texto. Estas palabras forman lo que se llama *codebooks* o vocabulario. Este mismo planteamiento se puede emplear a la hora de clasificar imágenes, pero en lugar de palabras tendremos vectores de elementos que describen las características de dichas imágenes. En este caso se está planteando esta técnica para la detección del fondo pero por supuesto se puede usar a la hora de clasificar

los propios vehículos. Al ser una técnica no paramétrica estas palabras no pueden asociarse con distribuciones gaussianas. Hay que decir que este planteamiento no es muy usado en la detección de fondo.

K. Kim, T.H. Chalidabhongse, D. Harwood and L. Davis [29] dicen que 6 palabras son suficientes para clasificar un píxel. En el planteamiento de M. Mazaheri and S. Mozaffari [30] la detección esta basada en *codebooks*.

Otro de los métodos empleados en la detección de fondo son los basados en la estimación no paramétrica de la función de densidad a partir de un número de muestras determinadas. Un caso muy popular de este método son los histogramas, los cuales representan la frecuencia de cada valor de forma gráfica a través de barras. Con ello se puede ver la distribución de los datos. A. Elgammal, D. Harwood and L. Davis [31] han aplicado este método para la estimación del fondo.

2.1.2. Técnicas basadas en DeepLearning

Todas las técnicas que se han ido comentando basan la detección de vehículos en la detección del fondo. En función de este fondo pueden saber cuales son los objetos que se encuentran en movimiento. Actualmente ha tomado mucha popularidad el *Deep Learning*, gracias a lo cual podemos ser capacez de detectar objetos con grandes resultados sin necesidad de tener que detectar el fondo.

Rigoberto Vizcay [32] se basa en redes Convolutional Neural Network (CNN) para la detección de vehículos y peatones. Una red neuronal convolucional es una red que presenta una o varias capas convolucionales. HAY QUE AÑADIR MAS COMENTARIOS!

Y. Abdullah, G. Mehmet, A. Iman and B. Erkan [3] plantean el uso de Region-based Convolutional Neural Network (R-CNN) y Faster R-CNN para la detección de vehículos. Por un lado, R-CNN para realizar las detecciones realiza tres fases que se pueden ver en la Figura 2.1:

1. Se emplea el algoritmo Selective Search, el cual solo realiza las pruebas de detección a las regiones candidatas a tener una posible detección. Con ello se extraen aproximadamente 2000 regiones de la imagen (Region Proposal).
2. Se implementa una red neuronal Convolutional Neural Network (CNN) en la parte superior de cada región.

3. Se extrae la salida de cada CNN y se ingresa en una Support Vector Machine (SVM) para clasificar la región. Además se realiza una regresión lineal para restringir el cuadro de la detección.

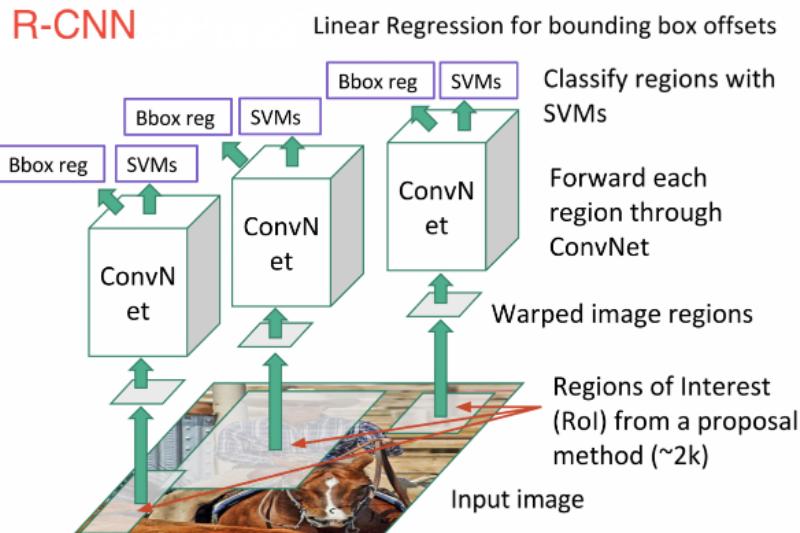


Figura 2.1: Fases de R-CNN

Por otro lado, Faster R-CNN es una versión más rápida que R-CNN, en la que se modifican algunos aspectos. En este método se incluye la técnica *region proposal*, la cual determina qué regiones de la imagen tienen mayor probabilidad de contener objetos y por tanto cuáles son las regiones que se introducirán en el clasificador. Esto optimiza mucho el trabajo pues evita introducir al clasificador regiones que no sean de interés.

Ignacio Arriola [33] hace también uso de Faster R-CNN. En este trabajo se han entrenado y comparado tres redes Faster R-CNN para la detección de peatones partiendo de diferentes parámetros iniciales. Con ello se pretendía estudiar la transferencia del aprendizaje, experimentando con dos redes pre-entrenadas y una inicializada con parámetros aleatorios. Las redes pre-entrenadas se trataban de una Faster-R-CNN [34] y una red convolucional Resnet 101 [35] como extractor de características. Cada modelo fue entrenado con una base de datos diferente (uno con Common Objects in Context (COCO)¹ y otro con KITTI²). Tras realizar las pruebas concluyeron que el caso que peores resultados obtenía era el que tenía valores iniciales aleatorios. También se ha analizado

¹<http://cocodataset.org/#home>

²<http://www.cvlibs.net/datasets/kitti/>

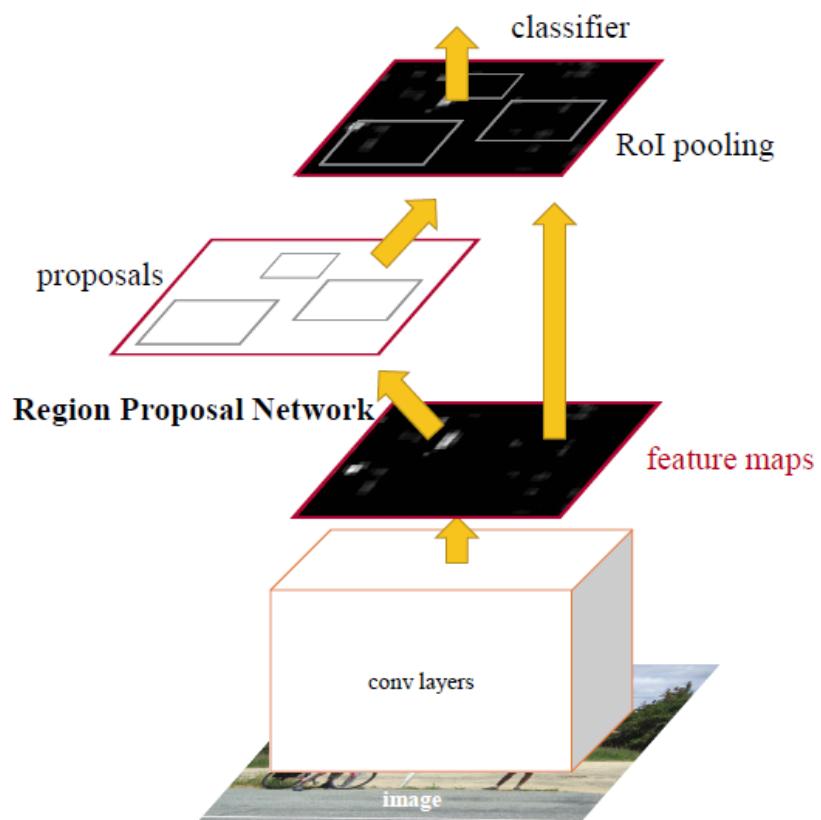


Figura 2.2: Fases de Faster R-CNN

un caso práctico de detección de baches en carretera con los mismos modelos empleados en la detección de peatones.

2.2. Clasificación de vehículos

La clasificación de vehículos trata de determinar a qué clase pertenece cada objeto detectado. Analizando los trabajos que se centran en este problema se ha podido ver que son tres los métodos más empleados:

- Técnicas basadas en características.
- Técnicas basadas en modelos 3D.
- Técnicas basadas en *Deep Learning*

2.2.1. Clasificación basada en características

Las técnicas basadas en características se centran en extraer propiedades de la imagen que permitan poder clasificar cada objeto. En el caso de la clasificación de vehículos, tratarán de definir un conjunto de características con las cuales pueda quedar bien descrito el vehículo en cuestión. Para ello se necesitará mucha información, cuantas más características tengamos del objeto será más fácil de describir. En esta familia de técnicas se requiere una fase de entrenamiento previa donde el sistema sea capaz de aprender las diferentes características. Una vez tengamos el sistema entrenado le pasaremos los objetos detectados, para que estime a qué clase pertenecen. Dicha clase será siempre la que más características tenga en común con el objeto que pretendemos clasificar.

Las características pueden ser visuales o geométricas (longitud, área, relación entre el alto y el ancho, etc). En el caso de las características geométricas Shih-Hao Yu et al. [36] presentaron un sistema que era capaz de distinguir entre tres clases: camiones, autobuses y coches. Para ello se basaba en dos características (tamaño y linealidad). La linealidad se empleaba para distinguir entre autobuses y camiones.

Jin-Cyuan Lai, Shih-Shinh Huang and Chien-Cheng Tseng [37] definieron las mismas clases que en [36] (coches, camiones y autobuses). Ellos se basaban en la compacidad y la proporción entre el ancho y el alto de los cuadros detectados. Además filtran los blobs en función de estas restricciones con el fin de eliminar ruido y blobs muy pequeños.

H. Asaidi , A. Aarab and M. Bellouki [38] definieron tres categorías: furgonetas, coches y camiones. Para definir cada vehículo determinaron 7 características geométricas. En función a estas 7 características calculaban la distancia euclídea entre el vehículo detectado y las categorías definidas. El vehículo era clasificado a la categoría con la que se obtenía menor distancia.

Las características visuales son más complejas que las geométricas, pues tratan de definir la forma y el aspecto de cada objeto. Para ello emplean descriptores. Dos descriptores que tienen mucha relevancia son el descriptor Histogram of Oriented Gradients (HOG) y el descriptor Haar. C.P. Papageorgiou, M. Oren and T. Poggio [39] fueron quien introducieron los descriptores Haar para la detección de caras humanas. Navneet Dalal and Bill Triggs [40] propusieron el descriptor HOG para detectar peatones.

A partir del descriptor HOG hay alguna variante como por ejemplo el descriptor 3DHOG. Buch et al. [26] ya emplearon este descriptor para detectar el fondo, el cual combina puntos de interés 3D y HOG.

Estos descriptores son muy aplicados en el mundo de la clasificación de objetos gracias a los buenos resultados que se ha visto que obtienen. HOG suele mezclarse con algún otro clasificador, pues se ha visto que da muy buenos resultados.

Bailing Zhang, Yifan Zhou and Hao PanTammam Tillo [41] presentaron un método basado en Kernel Auto Associator (KAA) para la clasificación de vehículos. A la hora de detectar los vehículos empleaban HOG combinado con clasificadores *Support Vector Machine (SVM)* en cascada. Para la clasificación también hicieron uso de (*Edge Orientation Histogram (EOH)*) como característica discriminante.

Otra técnica que ha sido aplicada a la hora de clasificar vehículos es la técnica *eigenfaces*, la cual fue introducida por L. Sirovich and M. Kirby [42] para detectar y reconocer caras. Wei Wang, Yulong Shang, Jinzhi Guo and Zhiwei Qian [43] fueron unos de los autores que aplicaron la técnica de *eigenfaces* (se trata de construir con características un subespacio de vectores) para la clasificación de vehículos. En este trabajo en concreto tan solo clasificaban las detecciones como coches o no coches. Inicialmente es necesario entrenar al sistema con una base de datos. Tras este aprendizaje ya se podrán clasificar los vehículos. Para ello se capture la parte frontal del vehículo y se le aplican operaciones de post-procesado para emplearlas en la entrada del clasificador. Esta proyección de la parte frontal del vehículo es comparada con las proyecciones recopiladas para el entrenamiento. Si la comparación se encuentra por debajo de un umbral fijado se considerará que la

clasificación se ha realizado correctamente.

Hasta ahora hemos hablado de sistemas que empleaban técnicas basadas en características geométricas o visuales. Las características visuales ofrecen grandes ventajas frente a las geométricas, las cuales son muy susceptibles ante cambios de posición de la cámara o vehículos con geometrías similares. Por el contrario las características visuales son muy complejas y requieren de una fase de entrenamiento. Por ello lo ideal es hacer uso de ambas características, para así conseguir un sistema muy robusto. Dentro de este contexto tenemos a Zezhi Chen and Tim Ellis [2], los cuales presentan un sistema que emplea dos conjuntos de características. Uno de ellos *Measurement Based Features (MBF)* formado por hasta 13 características, entre las cuales tenemos el perímetro, el área, etc. Y otro conjunto llamado *Intensity-based on a Pyramid of Histogram of Gradient Orientations (IPHOG)*, los cuales codifican la forma y la distribución de los objetos dentro de la imagen. Las características son introducidas en un clasificador SVM, el cual realiza un entrenamiento para aprender dichas características. En la Figura 2.3 podemos ver un ejemplo de detecciones de este sistema.

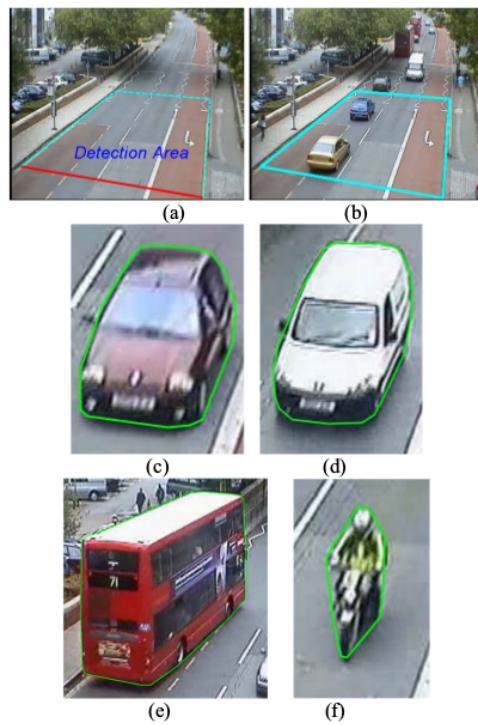


Figura 2.3: Detecciones del sistema de Zezhi Chen and Tim Ellis [2]

2.2.2. Clasificación basada en modelos 3D

En las técnicas basadas en modelos 3D es necesario conocer los parámetros de la cámara que se emplee. En este caso tendremos una plantilla por cada clase y compararemos dicha plantilla con el objeto a clasificar, para ver cuál es la clase que más se le ajusta. Wook-Sun Shin, Doo-Heon Song and Chang-Hun Lee [44] presenta un sistema basado en plantillas 3D que no necesita una cámara calibrada. Este sistema se basa en los puntos de fuga de los carriles para reconstruir la forma 3D de cada vehículo. Un ejemplo de esta reconstrucción se puede ver en la Figura 2.4

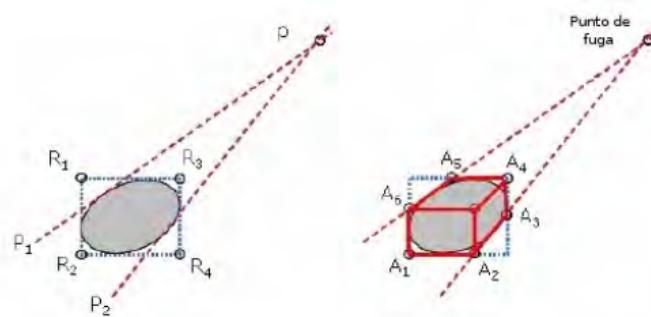


Figura 2.4: Reconstrucción 3D empleando puntos de fuga

Este sistema se basa en el algoritmo C4.5 de Quinlan [45] a la hora de clasificar. Este algoritmo emplea la construcción de árboles de decisión para clasificar y aprender las siluetas de los vehículos. Un ejemplo de esta técnica puede verse en la Figura 2.5.

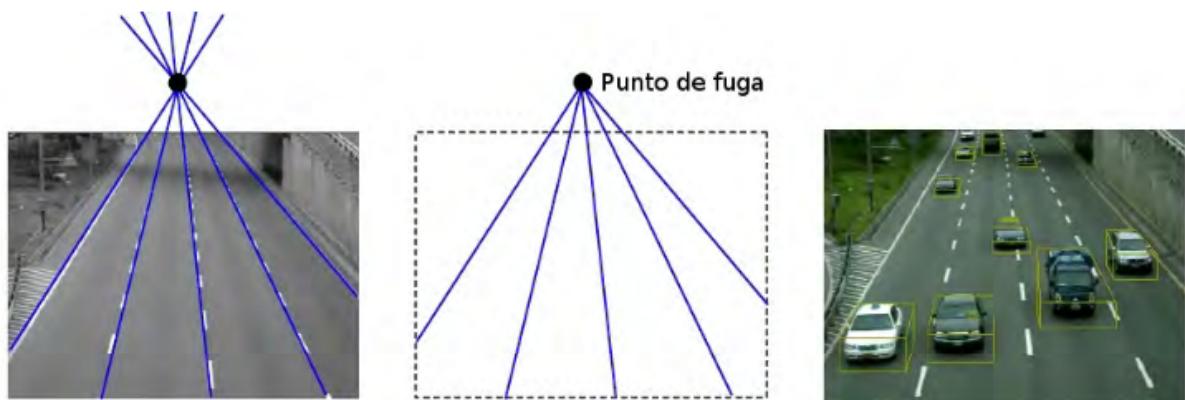


Figura 2.5: Clasificación de vehículos basada en modelos 3D construidos mediante el uso de puntos de fuga

Buch et al. [26] presentaron un sistema que combinaba plantillas 3D con HOG para clasificar los diferentes vehículos y los peatones. Este sistema se llama 3DHOG, y en él aplican descriptores HOG a plantillas 3D que definen los vehículos. Para cada categoría se define una plantilla 3D que permita definirla. En la Figura 2.6 se puede ver un ejemplo de dichas plantillas.

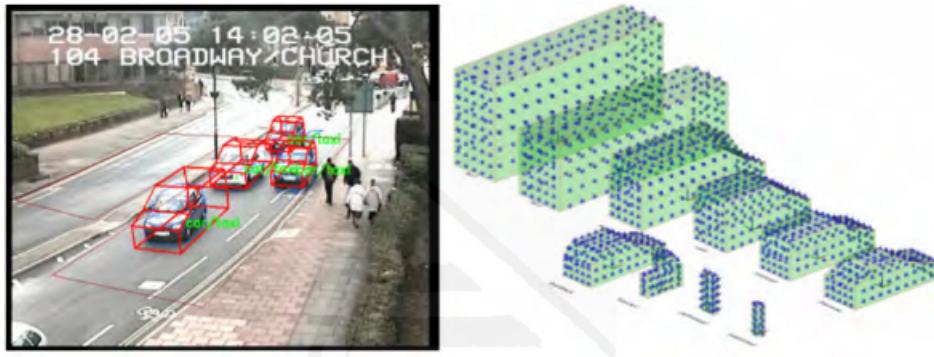


Figura 2.6: Plantillas 3DHOG para la clasificación de vehículos

En este sistema es necesario un previo entrenamiento. A la hora de realizar las clasificaciones se proyectan las plantillas 3D sobre los vehículos detectados y se les aplica transformaciones afines para ajustarlas al vehículo en cuestión. Tras esto se calculan sus histogramas 3DHOG y se comparan con los que se han aprendido en la fase de entrenamiento. Esta reconstrucción de los histogramas 3DHOG puede verse en la Figura 2.7.



Figura 2.7: Reconstrucción del histograma 3DHOG

2.2.3. Clasificación basada en DeepLearning

Tal y como se ha comentado en la Sección 2.1 actualmente se ha extendido mucho el uso de *Deep Learning* tanto para la detección como para la clasificación de objetos. A.F.

Granados y J.I. Marin.H [19] extraen los descriptores de Fourier de los vehículos detectados y los clasifican mediante una red neuronal. Dicha red neuronal consta de cuatro capas: una capa de entrada con una neurona por característica, dos capas ocultas con siete neuronas cada una y una capa de salida con una neurona clase. Shuang Wang, Zhengqi Li, Haijun Zhang, Yuzhu Ji and Yan Li [46] presentaron Convolutional Neural Network (CNN) como método para la clasificación de vehículos. Su método empleaba CNN para aprender las propiedades más relevantes de la imagen.

Edgar Camilo Camacho Poveda [47] emplea una red CNN para clasificar algunos vehículos en bus, microbus, minivan, sedan, SUV y camión. Como *framework* de desarrollo usan Caffe y parten de una red pre-entrenada de AlexNet. Dicha red había sido entrenada con el *dataset* ImageNet, el cual contiene millones de imágenes clasificadas en 1000 categorías. En este trabajo se plantearon 6 posibles clases: buses, microbuses, minivans, sedan, camionetas y camiones. En la Figura 2.8 se puede ver la arquitectura de AlexNet.

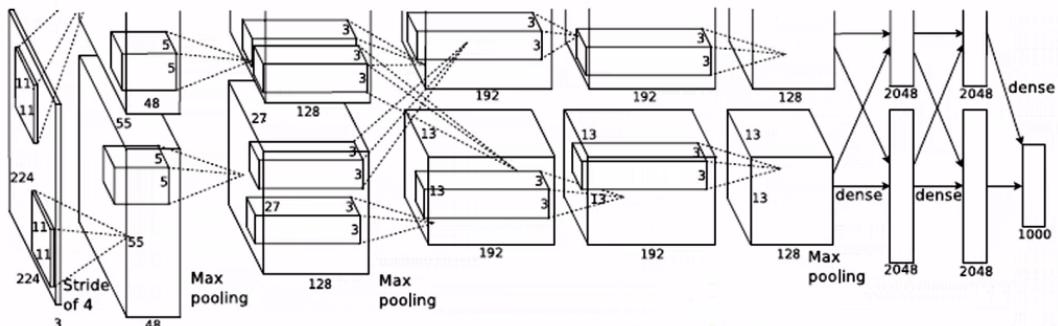


Figura 2.8: Arquitectura AlexNet

2.3. Seguimiento de vehículos

El seguimiento es la localización de un objeto a medida que va moviéndose por la imagen. Para el ser humano es una tarea muy sencilla, pero para la visión artificial se trata de un tema complejo, pues pueden cambiar muchas características en el objeto a medida que avanza en la imagen. Por ejemplo la forma, la iluminación, el tamaño, cambios en la perspectiva, occlusiones, movimiento de la cámara, etc.

Las técnicas más empleadas en el seguimiento de vehículos son:

- Seguimiento basado en regiones

- Seguimiento basado en características
- Seguimiento basado en modelos

2.3.1. Seguimiento basado en regiones

Las técnicas basadas en las regiones se centran en el seguimiento de regiones conexas del objeto. Normalmente la propiedad que suele emplearse es el color. En los diferentes artículos publicados se puede ver el uso de diferentes espacios de color como RGB, el espacio CEI lab o CEI LUV, el espacio HSV, etc. Lo más común es el uso de histogramas de color que nos permiten representar las regiones. Estas técnicas fueron introducidas por D. Comaniciu, V. Ramesh and P. Meer [48]. El seguimiento se basa en la comparación de los histogramas de las nuevas imágenes con el histograma de las regiones de interés calculadas en imágenes previas. Para ver el parecido entre los histogramas se emplea una medida similar a la distancia de Bhattacharyya y *mean-shift* para optimizar la selección del candidato.

Stefan Duffner and Christophe Garcia [49] presentó un algoritmo llamado *PixelTrack*, el cual combina la transformada de Hough con un modelo genérico de detección de fondo. Para ello necesita inicializar una ventana sobre el objeto. Gracias a esta técnica son capaces de seguir objetos en tiempo real con fondo cambiante, occlusiones y condiciones desfavorables. Lili Huang and M. Barth [43] plantean un algoritmo para llevar a cabo el seguimiento de vehículos y la resolución de occlusiones. En este algoritmo emplean un modelo de color basado en *mean-shift* para identificar a qué vehículo pertenece cada parche de 3x3 píxeles cuando existe una occlusión.

2.3.2. Seguimiento basado en características

Tal y como su nombre indica este seguimiento se centra en seguir los objetos en función a las características que se crean oportunas. Cada autor hace uso de unas características. Entre estas características tenemos puntos característicos como esquinas, el perímetro del objeto, sus dimensiones, etc. Si lo comparamos con el seguimiento basado en regiones podemos ver que es más robusto, pues en el caso de las regiones trataban de seguir el objeto en función del color o la textura, lo cual es muy susceptible ante el cambio de iluminación. Entre las técnicas más empleadas en este ámbito podemos encontrar Scale-Invariant Feature Transform (SIFT)(D.G. Lowe [50]) y Kanade–Lucas–Tomasi (KLT) (J.

Shi and C. Tomasi [51]). Otra técnica muy empleada en la literatura es HOG (Dalal and Bill Triggs [40]), la cual en muchas ocasiones ha sido combinada con SVM, tal y como se ha comentado en la sección anterior, Zehzi Chen and Tim Ellis [2] ya hicieron uso de ambos métodos.

2.3.3. Seguimiento basado en modelos

Este tipo de seguimiento trata de beneficiarse del conocimiento que tenemos de los objetos para realizar plantillas 2D y 3D para detectar objetos en la imagen y poder realizar su seguimiento. M.J. Leotta and J.L. Mundy [52] emplean esta técnica para detectar vehículos haciendo uso de una plantilla deformable que se ajusta para identificar diferentes formas de vehículos. En la literatura también se ha combinado esta técnica con filtros de Kalman.

2.4. Bases de Datos para la detección de vehículos

La detección y clasificación de vehículos pretenden encontrar un vehículo en una imagen o en un vídeo y determinar qué tipo de vehículo es. Dado que queremos encontrar el vehículo en cuestión bajo diferentes circunstancias, es decir, en distintos entornos y diferentes iluminaciones, necesitaremos típicamente entrenar el modelo con un conjunto de imágenes representativo. Por este motivo, a lo largo de los últimos años han surgido en la comunidad internacional diferentes *datasets* con el fin de solucionar este problema.

2.4.1. GRAM Road-Traffic Monitoring

GRAM Road-Traffic Monitoring (GRAM-RTM)³ [53] [54] es un conjunto de datos para el seguimiento de vehículos en tiempo real. Consiste en 3 secuencias de video (Figura 2.9), grabadas bajo diferentes condiciones y con diferentes plataformas.

El primer video, llamado M-30 (7520 fotogramas), se grabó en un día soleado con una cámara Nikon Coolpix L20, con una resolución de 800 x 480 a 30 FPS. La segunda secuencia, llamada M-30-HD (9390 fotogramas), se grabó en una ubicación similar pero durante un día nublado, y con una cámara de alta resolución: una Nikon DX3100 a 1200 x 720 a 30 FPS. La tercera secuencia de video, llamada Urban1 (23435 fotogramas), se

³<http://agamenon.tsc.uah.es/> Personales/rlopez/data/rtm/



Figura 2.9: Imágenes de ejemplo del dataset GRAM Road-Traffic Monitoring

grabó en una intersección concurrida con una cámara de tráfico de video vigilancia con una resolución de 600 x 360 a 25 FPS.

Todos los vehículos en el conjunto de datos GRAM-RTM fueron anotados manualmente. Este conjunto posee las siguientes categorías de clases: coches, camiones, furgonetas y camiones grandes. El número total de objetos diferentes en cada secuencia es: 256 para M-30, 235 para M-30-HD y 237 para Urban1. Todas las anotaciones en el conjunto GRAM-RTM se crearon en un formato XML compatible con PASCAL VOC.

2.4.2. BIT-Vehicle Dataset

El conjunto de datos BIT-Vehicle⁴[55] contiene 9850 imágenes de vehículos. Contiene imágenes con tamaños de 1600 x 1200 y 1920 x 1080. Estas imágenes (Figura 2.10) fueron capturadas desde dos cámaras en diferentes momentos y lugares. Las imágenes contienen cambios en las condiciones de iluminación, la escala, el color de la superficie de los vehículos y el punto de vista. Las partes superior o inferior de algunos vehículos no están incluidas en las imágenes debido a la demora en la captura y al tamaño del vehículo.

En cada imagen puede haber uno o dos vehículos y la ubicación de cada vehículo está previamente anotada. Además, el conjunto de datos se puede utilizar para evaluar el rendimiento de la detección de vehículos.

Los vehículos del conjunto de datos se dividen en seis categorías: bus, microbus, minifurgoneta, Sedan, SUV y camión. El número de vehículos por tipo de vehículo es de 558 para bus, 883 para microbus, 476 para minifurgoneta, 5922 para Sedan, 1392 para SUV, y 82 para camiones.

⁴<http://iitlab.bit.edu.cn/mcislab/vehicledb/>

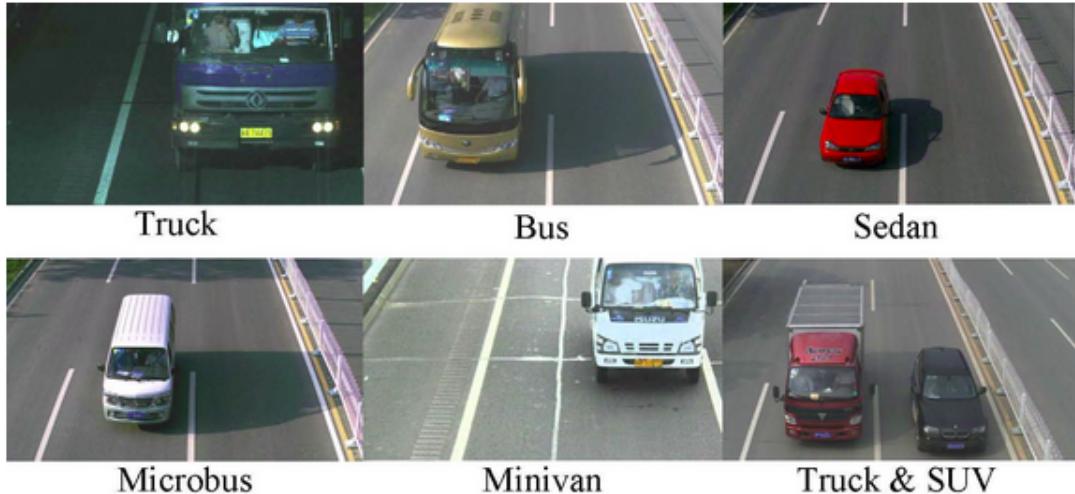


Figura 2.10: Imágenes de ejemplo del dataset BIT-Vehicle

2.4.3. CarND-Vehicle-Detection

CarND-Vehicle-Detection⁵[56] es un proyecto dedicado a la detección de vehículos en vídeo, por ello crearon dos conjuntos de datos que se pueden encontrar en [57].

El *dataset 1* incluye datos de conducción en Mountain View California y las ciudades vecinas durante el día. Contiene más de 65000 etiquetas en 9423 imágenes almacenadas por una cámara de investigación Point Grey que se ejecuta a una resolución máxima de 1920x1200 a 2Hz. El conjunto de datos fue anotado mediante CrowdAI utilizando una combinación entre aprendizaje automático y el trabajo de personas. Este conjunto de datos ocupa un total de 1.5 GB, y las clases que contiene son: coche, camión y peatón.

El *dataset 2* es similar al conjunto de datos 1, pero contiene campos adicionales para la oclusión y una etiqueta adicional para los semáforos. El conjunto de datos fue anotado en su totalidad por humanos usando Autti y es un poco más grande que el anterior con 15000 imágenes (ocupa 3.3 GB). Este conjunto incluye las clases: coche, camión, peatón y farolas.

⁵<https://github.com/udacity/CarND-Vehicle-Detection>



Figura 2.11: Imágenes de ejemplo del dataset 2 de CarND-Vehicle-Detection

Capítulo 3

Herramientas utilizadas

En este capítulo se van a explicar las diferentes bibliotecas software y entornos que se van a emplear, así como los lenguajes de programación de los que haremos uso.

Como lenguajes de programación se ha hecho uso de *Python* y *C++*. La aplicación se ha desarrollado casi en su totalidad en *C++*, Aunque la integración de *TensorFlow* y *Keras* se ha realizado con la versión 2.7.12 de *Python*. Para el desarrollo del modelo de *Deep Learning* que se empleará para la detección, se han realizado pruebas con *TensorFlow*, *Keras* y *Darknet*. *OpenCV* se ha usado para todo lo relacionado con el tratamiento de imágenes. Finalmente la evaluación experimental de la eficacia de la aplicación desarrollada se ha realizado con la herramienta *DetectionSuite*.

La interfaz gráfica de la aplicación desarrollada se ha hecho con *gtkmm* en *C++*, herramienta que permite crear interfaces de usuario con múltiples funcionalidades.

3.1. DetectionSuite

En este proyecto se ha hecho uso de la herramienta *DetectionSuite* [58] para evaluar los resultados de las redes neuronales entrenadas y de nuestra aplicación de monitorización visual de tráfico rodado.

DetectionSuite es una herramienta que permite evaluar diferentes tipos de redes neuronales sobre un conjunto de datos. La idea es ofrecer una infraestructura genérica para evaluar los algoritmos de detección de objetos contra un conjunto de datos estandarizado y calcular las estadísticas más comunes:

- *Intersection Over Union (IOU)*

- Precisión

- *Recall*

La *Intersection Over Union (IOU)* en la detección de objetos mide la precisión de un detector en un conjunto de datos en particular y sigue la siguiente fórmula:

$$IoU = \frac{\text{Area of Overlap}}{\text{Area of Union}} \quad (3.1)$$

Donde *Area of Overlap* es el área que pertenece a la intersección entre la predicción y la realidad, mientras que *Area of Union* es el área suma (sin repetición del solape) de la predicción y la realidad según muestra la Figura 3.2.

En la Figura 3.1 se puede ver un ejemplo visual del *ground-truth* y la predicción obtenida. En este caso el *Area of Overlap* es el área que incluye únicamente la intersección entre lo que hemos predecido y el *ground-truth*. Y el *Area of Union* es el área que se forma entre el *ground-truth* y la predicción.

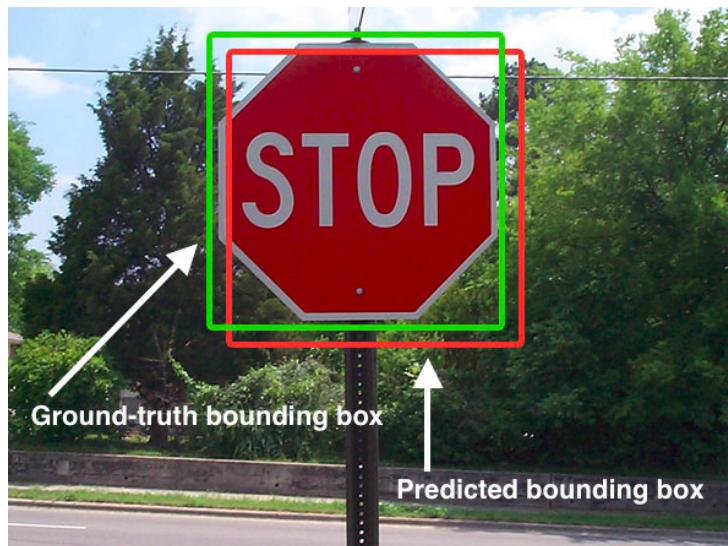


Figura 3.1: Ejemplo de IOU

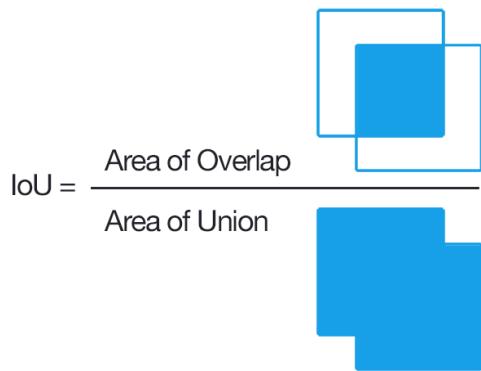


Figura 3.2: Fórmula IOU

Antes de explicar la precisión y el *recall* hay que aclarar algunos términos empleados a la hora de evaluar los resultados de las detecciones.

- *True Positive (TP)*: son los verdaderos positivos, es decir aquellas detecciones que se han hecho correctamente.
- *False Positive (FP)*: falsos positivos. Son aquellas detecciones que se han hecho pero son erróneas.
- *False Negative (FN)*: falsos negativos. Es la proporción de casos positivos que la prueba detecta como negativos, es decir objetos que no se han detectado y deberían haberse detectado.
- *True Negative (TN)*: verdadero negativo. Se refiere a los *boundingbox* que no deben detectarse en la imagen y no se han detectado. Este valor no se emplea en las métricas.

La precisión se trata del total de detecciones correctas entre la cantidad de detecciones obtenidas. La precisión que obtiene *DetectionSuite* es la promediada (*mean Average Precision (mAP)*), para aquellas predicciones que tienen un IOU mayor que un umbral (0.5).

$$\text{Precision} = \frac{TP}{TP + FP} \quad (3.2)$$

El *recall* es la cantidad de detecciones correctas entre la cantidad de detecciones reales, es decir las detecciones del *ground-truth*. Al igual que la precisión, se obtiene un

promediado (*mean Average Recall (mAR)*) de las detecciones que tienen un IOU superior a 0.5.

$$Precision = \frac{TP}{TP + FN} \quad (3.3)$$

Volviendo a *DetectionSuite*, es una herramienta que puede emplearse tanto en Linux como en MacOS. Permite evaluar modelos entrenados en *Tensorflow*, *Keras*, *Caffe* y *Darknet*. Los formatos de dataset que admite son: YOLO, COCO, *ImageNet Pascal VOC*, etc. A continuación se enumeran las entradas de imágenes soportadas:

- WebCamera/ USB Camera
- Vídeos
- Streams from ROS
- Streams from ICE
- JdeRobot Recorder Logs

En este TFM en concreto se va a hacer uso de la herramienta *AutoEvaluator* de *DetectionSuite*, la cual es capaz de evaluar múltiples redes en un solo conjunto de datos o múltiples conjuntos de datos en una sola ejecución. Todo lo que necesita es un archivo de configuración que contenga detalles sobre los conjuntos de datos y las redes. Los resultados se escriben en archivos CSV en el directorio de salida especificado.

3.2. Entorno TensorFlow

Para el desarrollo de la red neuronal que queremos aplicar en nuestra aplicación *Smart-Traffic-Sensor* se han probado diferentes plataformas de desarrollo de *Deep Learning*, entre ellas *TensorFlow*¹. Es una plataforma de código abierto *end-to-end* para el *Machine Learning* que fue liberada bajo licencia de *Apache 2* a finales de 2015 y que está disponible en github [59]. Fue desarrollada por el equipo de investigación en *Machine Learning* “*Google Brain*” en *C++* y *Python*, y es usado en multitud de productos y servicios de Google como *Gmail* o *Google Translation*. Google ofrece en su plataforma *Cloud* ejecutar *Tensorflow* en *Tensor Processing Unit (TPU)*, un nuevo tipo de procesadores en

¹<https://www.tensorflow.org/>

Cloud optimizados para ejecutar Inteligencia Artificial (IA). *TensorFlow* está orientado a problemas de *Deep Learning* y permite entrenar y construir redes neuronales.

TensorFlow puede correr tanto en CPUs como en GPUs (haciendo uso de Compute Unified Device Architecture (CUDA)). Está disponible en *Linux* de 64 bits, *MacOS*, y plataformas móviles que incluyen *Android* e *iOS*. Actualmente es el entorno más popular en *Deep Learning*.

Puede ejecutar de forma rápida y eficiente gráficos de flujo. Un gráfico de flujo está formado por operaciones matemáticas representadas sobre nodos, y cuya entrada y salida es un vector multidimensional o tensor de datos, por este motivo recibe el nombre de *TensorFlow*.

Las ventajas de este software se extienden a muchas disciplinas a parte de la tecnología TIC. Se emplea en medicina en imágenes médicas para la detección de tumores por ejemplo, también se usa en la detección y combinación de estilos artísticos en la pintura, etc.

En este TFM se emplea la versión 1.12.0 de *Tensorflow*.

3.3. Entorno Keras

Al igual que se ha empleado *TensorFlow* como plataforma de desarrollo de la red neuronal, se ha hecho uso de *Keras*². Es un entorno de alto nivel para el aprendizaje, escrito en *Python* y capaz de correr sobre *TensorFlow*, CNTK, o *Theano*. Fue desarrollado con el objetivo de facilitar el proceso de experimentación en redes neuronales de forma rápida y eficiente. Puede correr tanto en CPU como en GPU. Permite crear de forma sencilla y rápida los modelos de las redes neuronales (a través de su facilidad de uso, su modularidad y su extensibilidad). Admite redes convolucionales y redes recurrentes, así como combinaciones de las dos.

Inicialmente fue desarrollada en el proyecto de investigación ONEIROS (Open-ended Neuro-Electronic Intelligent Robot Operating System). Su creador es François Chollet, ingeniero de *Google*. En 2017, el equipo de *TensorFlow* de *Google* decidió dar soporte a *Keras* en la biblioteca de core de *TensorFlow*.

Al igual que *TensorFlow*, *Keras* se encuentra en *github* [60], pues es de código abierto.

Las principales ventajas de *Keras* son que es fácil de usar, modular, y relativamente

²<https://keras.io/>

fácil de extender, haciendo muy simple su uso. Con *Keras* puedes realizar redes neuronales de forma sencilla y con muy pocas líneas de código, a diferencia de *TensorFlow* que es algo más complejo.

En este proyecto se hace uso de la versión 2.2.4 de *Keras*.

3.4. Entorno Darknet

*Darknet*³ es un entorno para redes neuronales de código abierto escrito en C y CUDA. Es rápido, fácil de instalar y admite el empleo de CPU y GPU. El código se puede encontrar en github [61].

Darknet se creó con el fin de emplearse en el diseño, ejecución y entrenamiento de redes neuronales profundas para la clasificación y detección de objetos. Las principales ventajas de este sistema son su simplicidad en términos de uso y su tamaño reducido.

En nuestro proyecto haremos uso de You Only Look Once (YOLO), que es un sistema de detección de objetos que funciona sobre *Darknet*. YOLO utiliza *Deep Learning* y CNN para detectar objetos, y se distingue de sus competidores porque requiere de ver la imagen una sola vez, permitiéndole ser mucho más rápido que el resto de algoritmos. Gracias a su gran rapidez es capaz de detectar objetos en tiempo real en vídeos (hasta 30 *FPS*).

A la hora de realizar la detección, YOLO en primer lugar divide la imagen en una cuadrícula de SxS. En cada una de sus celdas se estiman sus N posibles *bounding boxes* con sus respectivas probabilidades de acierto. Teniendo así SxSxN *bounding boxes*. Aquellas predicciones que tengan una probabilidad por debajo de un umbral quedarán eliminadas. A las que superen dicho umbral se les aplicará *non-max suppression*, lo cual sirve para eliminar objetos detectados por duplicado. Este proceso puede verse en la Figura 3.3.

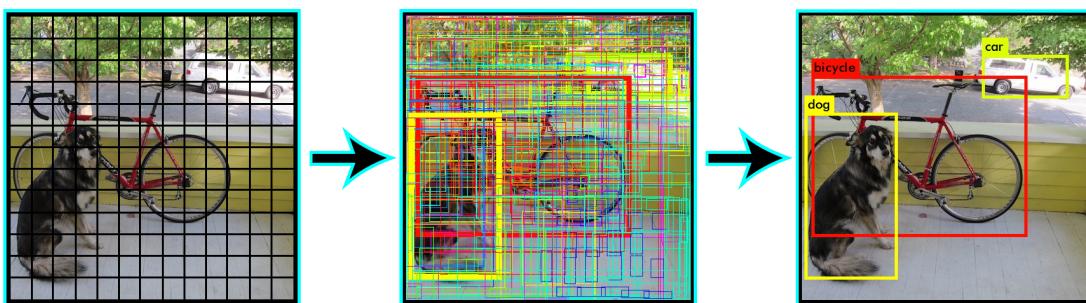


Figura 3.3: Proceso de Yolo

³<https://pjreddie.com/darknet/>

En este TFM se ha usado *Darknet* para el desarrollo de una red neuronal. La versión que se ha empleado es *YOLOv3*, es decir, la última versión existente hasta la fecha.

3.5. Biblioteca OpenCV

*OpenCV*⁴ es una librería de código abierto desarrollada por *Intel* y publicada bajo licencia de BSD. Esta librería implementa gran variedad de herramientas para la interpretación de la imagen. Sus siglas provienen de los términos anglosajones “*Open Source Computer Vision Library*”, y tal y como se puede deducir es una librería destinada a aplicaciones de visión por computador en tiempo real. Puede ser empleada en MacOS, Windows y Linux, y existen versiones para *C#*, *Python* y *Java*, a pesar de que originalmente era una librería en *C/C++*. Además hay interfaces para *Ruby*, *Python*, *Matlab* y otros lenguajes.

OpenCV implementa algoritmos para técnicas de calibración, detección de rasgos, rastreo, análisis de la forma, análisis del movimiento, reconstrucción 3D, segmentación de objetos y reconocimiento, etc. Los algoritmos se basan en estructuras de datos flexibles acopladas con estructuras IPL (*Intel Image Processing Library*), aprovechándose de la arquitectura de Intel en la optimización de más de las mitad de las funciones. Incorpora funciones básicas para modelar el fondo, sustraer dicho fondo y generar imágenes de movimiento MHI (*Motion History Images*). Además incluye funciones para determinar dónde hubo movimiento y en qué dirección.

⁴<https://opencv.org/>

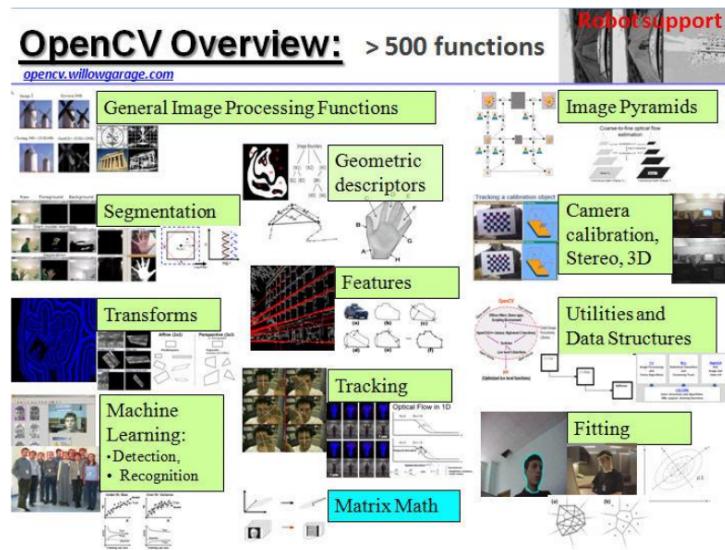


Figura 3.4: Funciones de OpenCV

Fue diseñado para tener una alta eficiencia computacional, está escrito en C y puede aprovechar las ventajas de los procesadores multinúcleo. Contiene más de 2500 funciones que abarcan muchas áreas de la visión artificial. También tiene una librería de aprendizaje automático (MLL, *Machine Learning Library*) destinada al reconocimiento y agrupación de patrones estadísticos.

Desde su aparición OpenCV ha sido usado en numerosas aplicaciones. Entre las cuales se encuentran la unión de imágenes de satélites y mapas web, la reducción de ruido en imágenes médicas, los sistemas de detección de movimiento, la calibración de cámaras, el manejo de vehículos no tripulados, el reconocimiento de gestos, etc. OpenCV es empleado también en reconocimiento de música y sonido, mediante la aplicación de técnicas de reconocimiento de visión en imágenes de espectrogramas del sonido.

Hay una gran cantidad de empresas y centros de investigación que emplean estas técnicas como IBM, Microsoft, Intel, SONY, Siemens, Google, Stanford, MIT, CMU, Cambridge e INRIA.

En este proyecto se hace uso de la versión *OpenCV 3.2*.

3.6. Biblioteca Gtkmm

*Gtkmm*⁵ es una encapsulación en *C++* de *Gtk+*. Dicha encapsulación ofrece todos los beneficios de la orientación a objetos, e incorpora otras cualidades como una mejora en la comprobación de tipos, código más reducido y legible, y un menor uso de los punteros.

Se trata de un *toolkit* para desarrollar interfaces gráficas de usuario. Es un software libre distribuido bajo la Licencia Pública General Reducida de GNU (LGPL).

Gtkmm se organiza por medio de ventanas, las cuales contienen *widgets*, como por ejemplo botones, etiquetas, cuadros de texto, etc. Para cada *widget* debemos tener un objeto C++ con el cual controlar su funcionamiento, es decir si por ejemplo nuestro *widget* es un botón, necesitaremos funciones para saber si se ha pulsado o no, y acerca de que realizar si se hubiera pulsado, para todo ello se emplea un objeto de C++.

Aunque se puede especificar el diseño y apariencia de las ventanas y *widgets* con C++, resulta más conveniente usar *Glade* para el diseño de la interfaz de usuario y cargarlos en tiempo de ejecución con *Gtk::Builder*. Con *Glade* podemos desarrollar las interfaces de usuario, guardarlas en formato .glade y luego cargarlas desde *gtkmm* empleando *Gtk::Builder*.

En este caso se hace uso de la versión *gtkmm* 3.0.

⁵<http://www.gtkmm.org>

Capítulo 4

Aplicación Smart-Traffic-Sensor para Monitorización de Tráfico Rodado

En este capítulo se hace una descripción del sistema desarrollado para llevar a cabo la monitorización visual de vehículos.

4.1. Bases de Datos de Entrenamiento

Dado que queremos encontrar los vehículos en cuestión bajo diferentes circunstancias, es decir, en diferentes entornos y con diferentes iluminaciones, necesitaremos entrenar el modelo neuronal con un conjunto de imágenes representativo. Por este motivo, a lo largo de los últimos años han surgido diferentes *datasets* públicos con el fin de permitir el entrenamiento de redes neuronales. Para el caso de la detección de vehículos hay pocos *datasets*, por ello ha sido necesario crear una base de datos propia que tuviera un número suficiente de muestras y una variación amplia de tipos de escenarios, de vehículos, condiciones de luz, etc.

Esta base de datos propia consta de:

- La base de datos recopilada por Redouane Kachach en su tesis doctoral, para la aplicación *TrafficMonitor*, que es antecesor directo de este TFM [62].
- La base de datos GRAM Road-Traffic Monitoring (GRAM-RTM) creada por R. Guerrero-Gomez-Olmedo, R. J. Lopez-Sastre, S. Maldonado-Bascon and A. Fernandez-Caballero [63].
- Imágenes recopiladas de cámaras en abierto de forma online durante este TFM.

Se ha tratado que la base de datos construida abarcara la mayor diversidad de vehículos posibles y en diferente tipos de escenarios. Hay que tener en cuenta que toda la base de datos tiene vehículos vistos por la parte trasera. En total consta de 9774 imágenes y está formada por 7 clases: *Car*, *Motorcycle*, *Van*, *Bus*, *Truck*, *Small-truck* y *Tank-truck*.

En estas 9774 imágenes tenemos un total de 48914 muestras repartidas tal y como se muestra en la Tabla 4.1.

Clases	Muestras
Car	38976
Motorcycle	1886
Van	5631
Bus	401
Truck	963
Small-Truck	938
Tank-Truck	119

Tabla 4.1: Muestras de la Base de Datos

Para intentar conseguir un sistema robusto ante diferentes condiciones, se ha han etiquetado en la base de datos imágenes en condiciones meteorológicas buenas, imágenes en condiciones meteorológicas malas (con niebla y lluvia) e imágenes de mala calidad. En la Tabla 4.2 se puede ver la cantidad de imágenes que hay para cada tipo.

	Nº de Imágenes
Buena calidad	8406
Malas Condiciones Meteorológicas	663
Mala Calidad	705

Tabla 4.2: Imágenes de la Base de Datos

En la Figura se pueden ver algunas imágenes de nuestra base de datos. FIGURAAA!! Hay que decir que todas las imágenes han sido etiquetadas a mano haciendo uso de la herramienta labelImg [64], la cual permite guardar las etiquetas en archivos xml en formato PASCAL VOC (formato usado por ImageNet) o en formato YOLO en txt.

4.2. Diseño de la Aplicación

DIAGRAMA un diagrama de entradas y salidas, como si fuera caja negra. Después un diagrama de bloques donde repasas cuales son los bloques constituyentes de la aplicación y cómo se conectan entre sí!!!!!

Smart-Traffic-Sensor es un sistema que se realizó con el objetivo de monitorizar tráfico rodado en tiempo real. Esta monitorización consta de tres elementos principales:

- Detección de vehículos
- Clasificación de vehículos
- Seguimiento de vehículos

Las detecciones y la clasificación van de la mano, pues se realizan con *Deep Learning*. En concreto con una red de YOLO. Los vehículos que detectemos los clasificaremos en función a 7 clases: *car*, *motorcycle*, *van*, *bus*, *truck*, *small-truck* y *tank-truck*. El seguimiento se centra en la proximidad espacial, y si esta falla se utiliza KLT. A todos los *blob* detectados se les realizará un seguimiento a lo largo del tiempo.

El sistema del que partíamos (*Traffic-Monitor* [17]) definía en la imagen una zona de entrada y otra de seguimiento. Esto puede verse en la Figura 4.1.

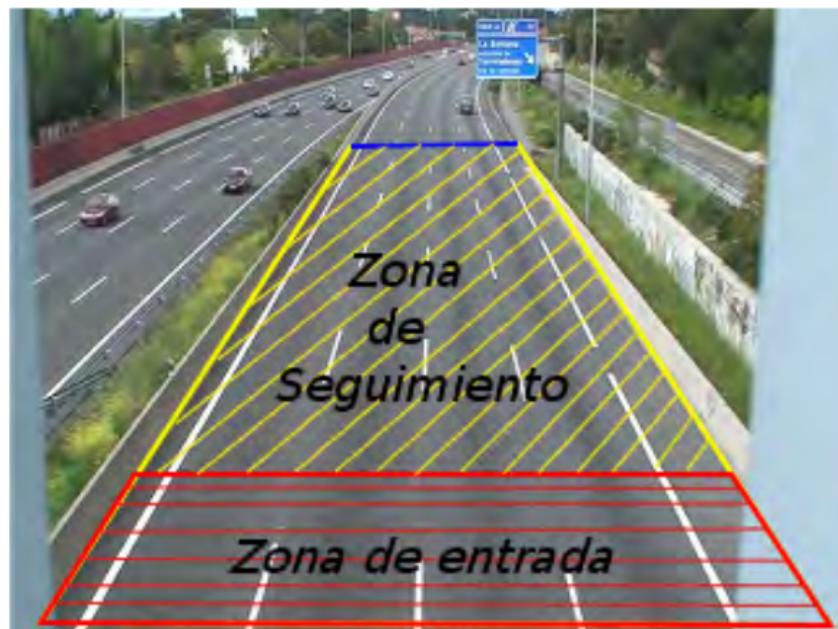


Figura 4.1: Zonas de entrada y seguimiento

En la zona de entrada se realizan las detecciones y en la de seguimiento es donde se lleva a cabo la clasificación y el tracking de los vehículos.

Este concepto de separar zona de entrada y seguimiento va a perder relevancia en nuestro sistema, pues ya no va a ser necesario hacer esta distinción. Tendremos una única zona en la que se lleve a cabo la detección, la clasificación y el tracking. Vamos a continuar teniendo una zona marcada en la imagen para identificar en qué parte de la carretera queremos centrar nuestras detecciones (por si existiesen carriles de diferente sentido). A esta zona de detección, clasificación y seguimiento vamos a llamarle zona de evaluación. En la Figura 4.2 se puede ver la zona de evaluación.



Figura 4.2: Zona Evaluación

Este trabajo se ha basado principalmente en el uso de *Deep Learning* para la clasificación y detección de vehículos. Además se ha apoyado en Kanade–Lucas–Tomasi (KLT), en los casos que pudiera haber pérdidas en la detección debido a occlusiones, o cuando los vehículos se encontraban muy alejados. Es decir, se ha apoyado en KLT cuando las condiciones a la hora de detectar eran algo complejas y por tanto el *Deep Learning* no era capaz de realizar correctamente la detección.

A la hora de realizar el *tracking* se hace uso de la proximidad espacial, pero esto se explicará con más detalle en las siguientes secciones.

En resumen se puede decir que tenemos dos grandes bloques:

- Detección y Clasificación de vehículos
- Tracking de vehículos

4.3. Detección y Clasificación

Nuestro sistema toma como imágenes de entrada las adquiridas del vídeo que se esté monitorizando. Dichas imágenes pasan como entrada a la red neuronal, donde se detecta y clasifican los diversos vehículos. Toda la información se almacena en cada instante, para así poder realizar el tracking en función de la información registrada del instante anterior.

Tal y como ya se ha comentado anteriormente se ha hecho uso de *Deep Learning*. En concreto se ha diseñado un sistema capaz de soportar redes neuronales entrenadas con diferentes *frameworks* (*TensorFlow*, *Darknet* y *Keras*) con el objetivo de detectar y clasificar los diferentes vehículos que aparezcan en la imagen. Con ello se ha pretendido realizar un sistema multiplataforma, el cual pueda adaptarse a los avances futuros de los diferentes entornos de *Deep Learning*. Esto hace que nuestra aplicación no quede limitada ante la evolución de las redes neuronales.

En vídeos en carretera es muy probable que tengamos occlusiones y por supuesto vehículos que se vayan alejando, los cuales son bastante complejos de detectar. Para solventar esto nos hemos apoyado en Kanade–Lucas–Tomasi (KLT). Por tanto tenemos un sistema que complementa *Deep Learning* con KLT.

Para tener un sistema lo más robusto posible se han tenido en cuenta varios detalles:

- Dentro de la zona de evaluación tenemos dos zonas. En la Figura 4.3 quedan identificadas esas dos zonas.

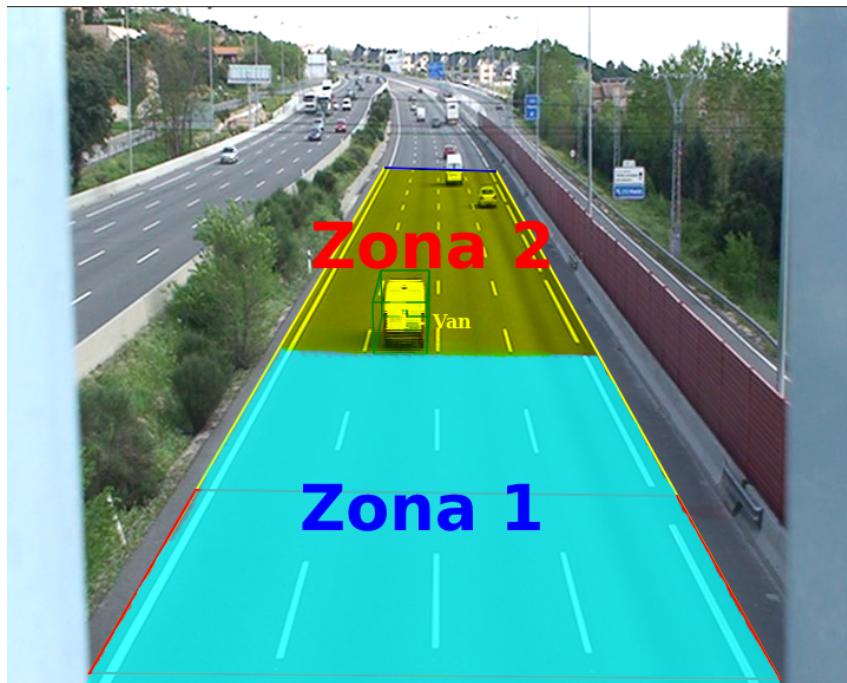


Figura 4.3: Zonas identificadas en la zona de Evaluación

La zona 1 se corresponde con la mitad de la zona de evaluación por donde entran los vehículos. En esta zona es más sencillo detectar y clasificar los vehículos pues tienen mayor tamaño. La zona 2 hace referencia a la mitad por la que salen los vehículos, la cual es más compleja, pues los vehículos tendrán menor tamaño.

- Un vehículo siempre va a entrar a la zona de evaluación por la parte de entrada. Nunca puede aparecer de repente. Por ello no puede aparecer ningún vehículo nuevo en el medio de la carretera, es decir nunca se podrá estimar que se ha detectado un vehículo nuevo en la zona 2.
- Si en la zona 1 un vehículo no es detectado durante 5 secuencias seguidas se dará por hecho que ha sido un falso positivo y por tanto quedará descartado.
- Todo vehículo que se encuentre en la zona 2 se considerará que es un vehículo correcto. Si mediante *Deep Learning* no somos capaces de detectar dicho vehículo, emplearemos KLT para localizarlo.

En resumen, hay que tener en cuenta que no pueden aparecer vehículos nuevos en medio de la imagen, por tanto si esto sucede se considerará un falso positivo y se descartará.

Otro aspecto que hay que tener en cuenta es que se podría dar una detección errónea, por ello si durante 5 secuencias seguidas un vehículo no ha sido detectado en la zona 1 se considerará como que era un falso positivo y se dejará de hacer su seguimiento.

Se han probado tres entornos diferentes para evaluar cual era el que mejores resultados obtenía. Para ello se hizo un primer entrenamiento con imágenes únicamente de buena calidad con el fin de determinar cual era el *frameworks* que mejor funcionaba.

En los siguientes puntos se va a explicar el diseño que se ha llevado a cabo para integrar cada plataforma, en la aplicación *Smart-Traffic-Sensor*.

4.3.1. Entorno TensorFlow y red SSD MobilenetV2

Para dar soporte dentro de la aplicación a redes de *TensorFlow* se ha hecho uso del *github models* de *TensorFlow* [65], con el cual podemos entrenar una red pre-entrenada con nuestra propia base de datos. En este caso se ha empleado una red Single Shot Detector (SSD) Mobilenet V2 entrenada con COCO, pues proporciona una buena relación entre la velocidad y la precisión. Para emplear dicha red se ha usado un archivo de configuración llamado *ssd_mobilenet_v2_coco.config* [66].

La red SSD MobileNet V2 es una red SSD que en lugar de tener una red VGG-16 de base, tiene una red MobileNet. En la Figura 4.4 se puede ver dicho diseño.

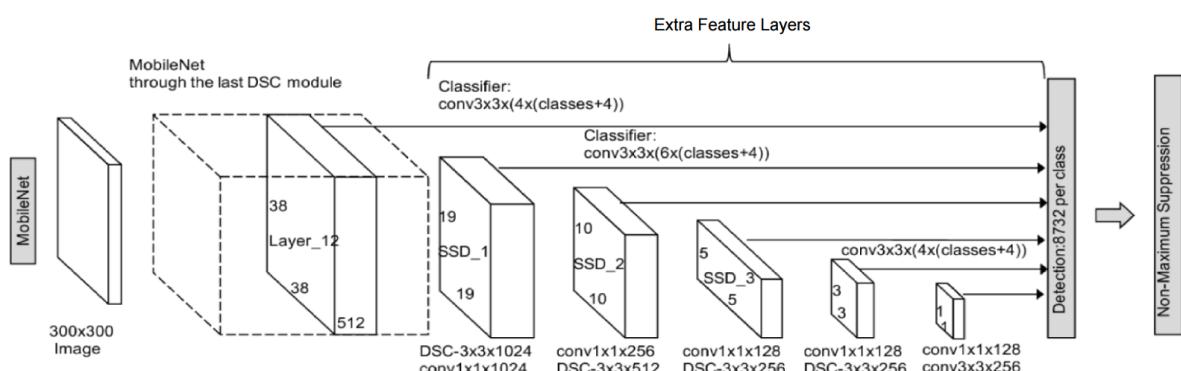


Figura 4.4: Red SSD Mobilenet V2

La primera parte de la red es la Mobilenet V2, en la cual se obtienen los mapas de características para poder realizar la clasificación y detección en las capas posteriores.

SSD [67] es un método de detección de objetos en imágenes empleando una única red neuronal profunda. SSD proporciona una gran ganancia de velocidad frente a Faster

R-CNN [68], que funciona a una tasa de 7 fotogramas por segundo. El enfoque de SSD se basa en una red convolucional *feed-forward* que produce un conjunto de *bounding boxes* de tamaño fijo y puntúa la presencia de instancias de clase de objeto en esos *bounding boxes*. Tras esto realiza *non-maximum suppression* para producir las detecciones finales.

Dada una imagen de entrada y un conjunto de etiquetas de *ground truth*, SSD realiza el siguiente proceso:

1. La imagen pasa a través de una serie de capas convolucionales, produciendo varios conjuntos de mapas de características a diferentes escalas.
2. Para cada ubicación en cada uno de estos mapas de características, emplea un filtro convolucional de 3x3 para evaluar un pequeño conjunto de *bounding boxes* por defecto.
3. Para cada *bounding box* predice simultáneamente el desplazamiento del *bounding box* y las probabilidades de clase.
4. Durante el entrenamiento hace que coincida el *bounding box* del *ground truth* con los *bounding boxes* predichos según *Intersection Over Union (IOU)*. El mejor *bounding box* predicho se etiquetará como "positivo", junto con todos los demás *bounding boxes* que tengan un ratio de *Intersection over Union* con el *ground truth* mayor de 0.5.

SSD parece sencillo, pero el entrenamiento tiene un desafío único. Clasificamos y estimamos *bounding boxes* desde cada posición en la imagen, usando múltiples formas diferentes, en diferentes escalas. Como resultado, generamos un número mucho mayor de *bounding boxes* que en otros modelos, y casi todos ellos son ejemplos negativos. Esto introduce un desequilibrio significativo entre los ejemplos de entrenamiento positivos y negativos.

Para solucionar este desequilibrio SSD hace dos cosas. En primer lugar, utiliza la Non-Maximum Suppression (NMS) para agrupar *bounding boxes* muy superpuestos en un solo *bounding box*. En otras palabras, si cuatro *bounding boxes* de formas, tamaños, etc. similares contienen el mismo objeto, el NMS conservará el que tenga la mayor confianza y descartará el resto. En segundo lugar, el modelo usa una técnica llamada minería negativa para equilibrar las clases durante el entrenamiento. En la minería negativa dura, solo se utiliza un subconjunto de los ejemplos negativos con la mayor pérdida de entrenamiento

(es decir, falsos positivos) en cada iteración de entrenamiento. SSD mantiene una relación de 3: 1 de negativos a positivos.

Mobilenet emplea unas capas llamadas *depthwise separable convolutions* en lugar de capas convolucionales para la clasificación. En una capa convolucional se extrae información mediante *kernels* que recorren toda la imagen. Estos *kernels* necesitan tener la misma profundidad que la imagen para ser aplicados, es decir, si tenemos una imagen RGB necesitaremos 3 *kernels*, uno por cada canal de color. Las capas *depthwise separable convolutions* siguen un proceso diferente a las convolucionales:

1. Realizan la operación *depthwise convolution*, en la cual se aplican *kernels* de igual profundidad que la imagen. Cada *kernel* se emplea en cada canal de color por separado.
2. Se lleva a cabo la operación *pointwise convolution* en la cual se aplica un *kernel* de 1x1xprofundidad de la imagen, con lo que se obtendrá así un único canal.

Finalmente estos *kernel* se combinan para obtener una única imagen. Si por ejemplo tenemos una imagen de 10x10x3 y se aplican capas convolucionales con *kernels* de 3x3x3 el resultado será una imagen de 8x8x1. Si queremos aplicar 5 *kernels* en total tendremos 5 *kernels* de tamaño 3x3x3 que se moverán por la imagen 8x8 posiciones.

$$N^{\circ} \text{operaciones} = 5 \times 3 \times 3 \times 3 \times 8 \times 8 = 8640 \quad (4.1)$$

En el caso de *depthwise separable convolutions* primero se realizará la operación *depthwise convolution* con la cual obtendremos una imagen de 8x8x3 . Es decir, se emplearán 3 *kernel*s de tamaño 3x3x1 para cada canal de color y estos *kernels* se moverán 8x8 posiciones. Tras esto se aplicará la operación *pointwise convolution*, en la cual se usará un *kernel* de tamaño 1x1x3 para obtener finalmente una imagen de 8x8x1. Si tuvieramos 5 *kernels* de tamaño 1x1x3 se moverán 8x8 posiciones.

$$N^{\circ} \text{operaciones} = (3 \times 3 \times 3 \times 1 \times 8 \times 8) + (5 \times 1 \times 1 \times 3 \times 8 \times 8) = 2688 \quad (4.2)$$

En conclusión, las capas *depthwise separable convolutions* realizan el mismo trabajo que las convolucionales pero lo dividen en dos, consiguiendo así reducir el número de operaciones.

Con el diseño que se ha explicado se ha entrenado un total de 3173 imágenes, de las cuales 2700 eran de *train* y 473 de validación. Las imágenes de *train* son las que se

usan para generar el modelo. Los datos de validación seleccionan el modelo que mejores resultados obtiene.

4.3.2. Entorno Keras y red SSD VGG-16

Con *Keras* se ha implementado una red SSD. Para ello se ha recurrido al diseño realizados por Pierluigi Ferrari [69], el cual define una red SSD que tiene como red base una VGG-16. En la Figura 4.5 se puede ver el diseño.

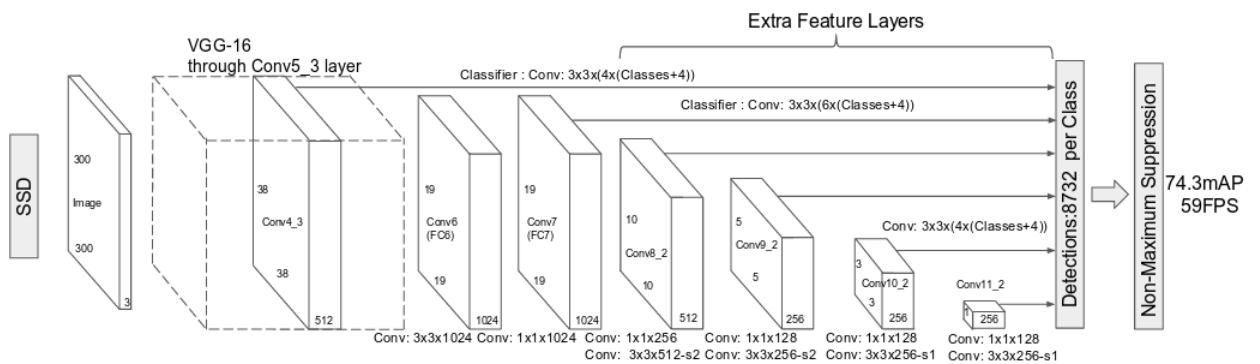


Figura 4.5: Red SSD

VGG-16 está formada por 16 capas, de las cuales 13 son capas convolucionales, 2 capas totalmente conectadas y una capa de *softmax* que se emplea para clasificar. En la Figura 4.6 se puede ver cuál es la arquitectura de la red VGG.

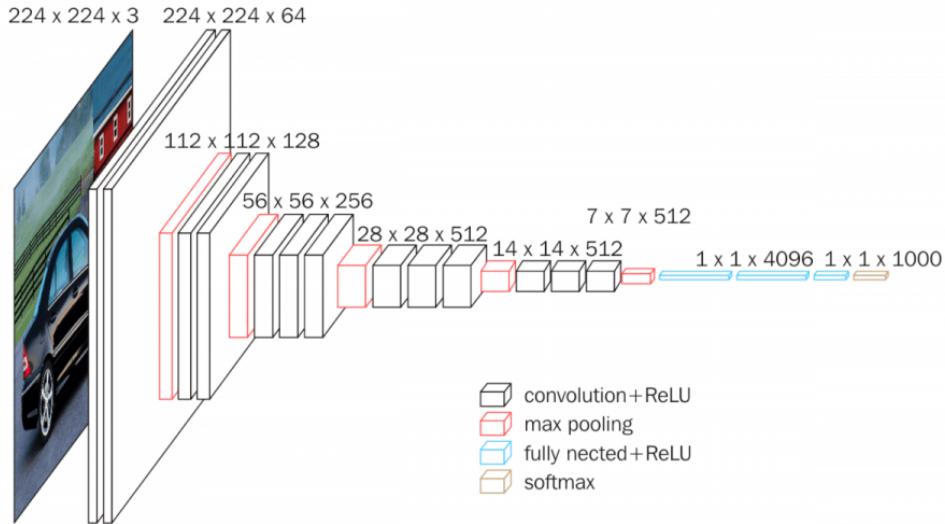


Figura 4.6: Red VGG-16

4.3.2.1. Entorno Darknet y red YOLOv3

En este sistema se ha incluido You Only Look Once (YOLO) debido a su gran éxito actualmente. YOLO [70] es otro enfoque para la detección de objetos. El trabajo previo a YOLO emplea clasificadores para realizar la detección. En esta aproximación se enmarca la detección de objetos como un problema de regresión en *bounding boxes* espacialmente separados y probabilidades de clase asociadas. En la evaluación, una red neuronal única predice *bounding boxes* y probabilidades de clase directamente desde imágenes completas.

YOLO impone fuertes restricciones espaciales en las predicciones de los *bounding boxes*, ya que cada celda de la cuadrícula solo predice dos *bounding boxes* y solo puede tener una clase. Esta restricción espacial limita el número de objetos cercanos que nuestro modelo puede predecir.

El modelo implementado es una red neuronal convolucional, donde las capas convolucionales iniciales extraen características de la imagen, mientras que las capas *fully connected* predicen las probabilidades y coordenadas de salida. La red tiene 24 capas convolucionales seguidas por 2 capas *fully connected*.

La arquitectura unificada de YOLO (Figura 4.7) es extremadamente rápida, procesando imágenes en tiempo real a 45 frames por segundo. Una versión más pequeña de la red, Fast YOLO, procesa 155 frames por segundo, logrando duplicar el *mean Average Precision (mAP)* de otros detectores en tiempo real.

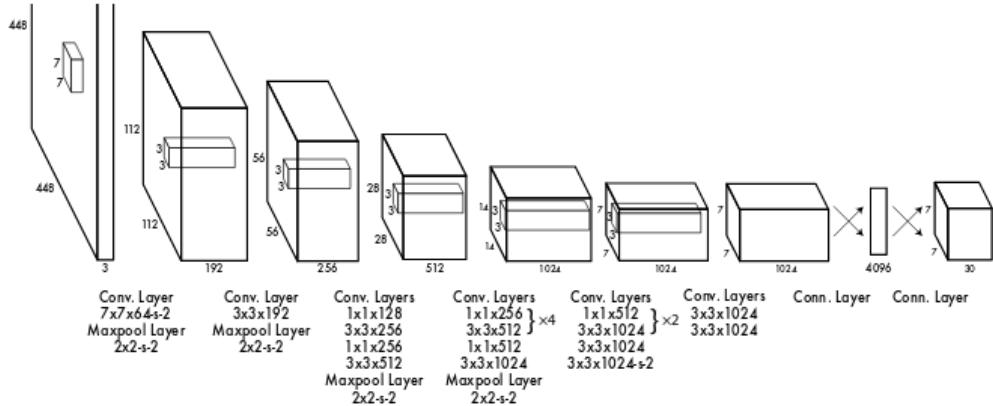


Figura 4.7: Arquitectura YOLO

En comparación con los sistemas de detección más modernos, YOLO comete más errores de localización (especialmente con objetos pequeños), pero es menos probable que prediga falsos positivos en el fondo. Finalmente, YOLO aprende representaciones muy generales de objetos. Supera a otros métodos de detección, como DPM y R-CNN, en imágenes naturales y trabajos artísticos.

4.4. Seguimiento de Vehículos

Una vez tenemos los vehículos detectados y clasificados debemos realizar su seguimiento a lo largo de la carretera. Es decir, tenemos que asociar cada *blob* detectado a los *blob* anteriores de los que ya se llevaba un seguimiento. El algoritmo empleado para realizar este *tracking* está basado en la proximidad espacial y KLT.

4.4.1. Emparejamiento por proximidad

La diferencia de píxeles en la imagen entre la posición de un vehículo en $t-1$ y en t es muy pequeña. Por tanto se puede decir que el *blob* de un vehículo en t cae en una zona muy cercana al *blob* de ese mismo vehículo en $t-1$. Esto se tendrá en cuenta a la hora de realizar el seguimiento, ya que cuando busquemos un vehículo en t deberíamos

encontrarlo en un radio circular pequeño alrededor de la posición de ese mismo vehículo en $t-1$.

El algoritmo que se plantea en cuanto a la proximidad espacial es el empleado por Redouane Kachach en la versión anterior de la aplicación [16]. En él se estima el área donde debería localizarse un vehículo en función de su posición en $t-1$. A medida que los vehículos vayan avanzando este área se irá actualizando.

Al principio el área se toma como un círculo pues no tenemos suficientes datos acerca de su orientación. Pero a medida que el vehículo avanza y tenemos suficiente información para conocer su orientación tomaremos el área como una elipse con centro en el centro del vehículo en $t-1$.

Consideraremos que tenemos suficiente información para estimar su orientación cuando tengamos 6 posiciones de un vehículo. Se emplea regresión lineal para calcular la orientación del vehículo basándonos en la posición que va tomando el vehículo a medida que va avanzando.

La regresión lineal consiste en minimizar $\sum_i \rho(r_i)$, donde r_i es la distancia con el i -ésimo punto y $\rho(r_i)$ es una función de la distancia. $\rho(r_i)$ se puede calcular como:

$$\rho(r_i) = 2\left(\sqrt{1 + \frac{r^2}{2}} - 1\right) \quad (4.3)$$

Una vez tenemos información acerca de la orientación definiremos el área de búsqueda como una elipse que tiene como centro el mismo que el vehículo en $t-1$ y dirección la calculada con la Fórmula (4.3).

Los emparejamientos entre los vehículos detectados en el instante t y los blob almacenados del instante $t-1$ se limita a los vehículos que caen dentro del área del círculo o la elipse que se obtiene en función de la posición del vehículo en el instante $t-1$. En la Figura 4.8 se puede ver la evolución que sufre el área alrededor del vehículo a medida que avanza.

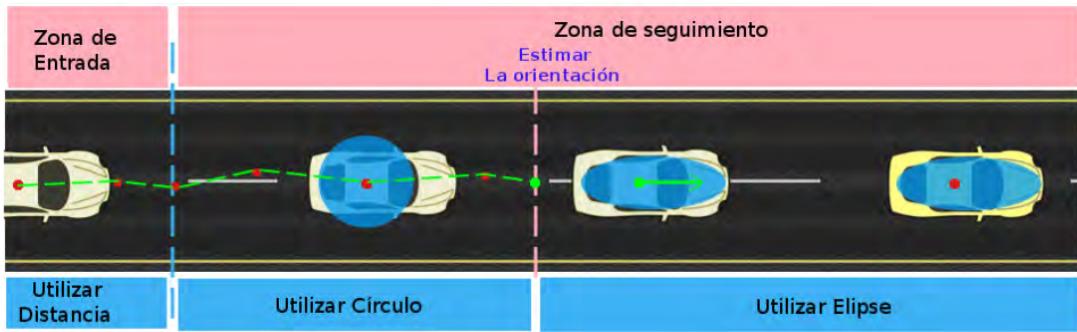


Figura 4.8: Evolución del área alrededor del vehículo

Estas elipses se definen como $C_{xc,yc,\omega}$, donde ω es la orientación y (x_c, y_c) es el centro del vehículo. Además a la hora de describir una elipse debemos conocer sus dos ejes. Estos parámetros se pueden ver en la Figura 4.9.

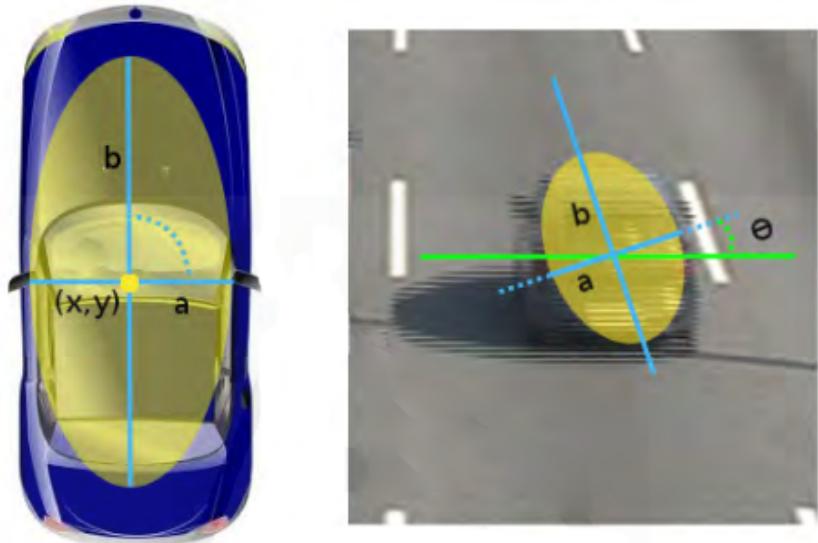


Figura 4.9: Elipse asociada a los vehículos

Un blob 2D cuyo centro es $B(x, y)$ se encontrará dentro de la elipse $C_{xc,yc,\omega}$ si se cumple:

$$C_\omega = \arctan\left(\frac{a_x}{a_y}\right) \quad (4.4)$$

$$\left(\frac{\cos(C_\omega)(B_x - C_{x_c}) + \sin(C_\omega)(B_y - C_{y_c})}{a}\right)^2 + \left(\frac{\cos(C_\omega)(B_y - C_{y_c}) - \sin(C_\omega)(B_x - C_{x_c})}{b}\right)^2 \leq 1 \quad (4.5)$$

a_x y a_y son los componentes del vector de orientación. En la Figura 4.10 se puede ver como se realiza el *tracking* entre dos *blob* consecutivos.

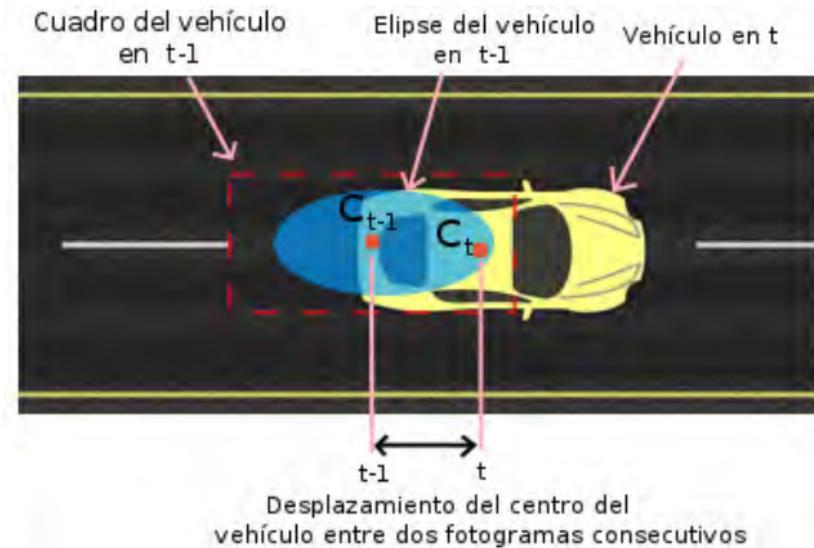


Figura 4.10: Seguimiento con proximidad espacial

En resumen, una detección deberá encontrarse dentro de un cierto área alrededor del *blob* detectado en $t-1$ para poder ser identificado como el mismo vehículo. Podría darse el caso de que dos vehículos cayeran en dicho área. Por ello es necesario tener en cuenta la distancia euclídea entre el centro del *blob* del instante $t-1$ y el centro de los *blob* en t . Aquel *blob* del instante t que se encuentre a menor distancia del *blob* del instante $t-1$ y por supuesto esté dentro del área alrededor del *blob* $t-1$ será considerado como el mismo vehículo que el de $t-1$. Es decir si esto se cumple el *blob* de $t-1$ y t corresponden al mismo vehículo pero en instantes consecutivos.

4.4.2. Seguimiento por KLT

El seguimiento se centra en asociar las detecciones actuales con los *blobs* almacenados del instante anterior. En el seguimiento se tendrán ciertos aspectos en cuenta:

- Si un *blob* llega al final de la zona de evaluación se eliminará del seguimiento.
- Se recorrerán los *blob* del instante $t-1$ almacenados con el fin de emparejarlos con los *blob* detectados en el instante t . Este emparejamiento se establecerá entre los *blob* t y $t-1$ que tengan menor distancia euclídea entre sus centros.

- Si el *blob* t asociado al *blob* $t-1$ no cae dentro del área circular o elíptica que se genera alrededor del centro del *blob* $t-1$ no quedará emparejado a éste.
- Si mediante proximidad espacial no somos capaces de emparejar un *blob* $t-1$ emplearemos KLT.

El seguimiento se basa principalmente en la proximidad espacial pero se hará uso de KLT en casos problemáticos, haciendo así más robusto nuestro sistema. KLT se calculará en todas las secuencias para ir actualizando los puntos característicos.

Si no se detecta un vehículo ya sea porque haya alguna oclusión o se encuentre muy lejos, se empleará KLT, pues se ha visto que funciona incluso ante oclusiones durante un pequeño número de fotogramas consecutivos.

Para poder realizar KLT necesitamos conocer el centro de masas de los vehículos y sus características visuales. En función de los puntos característicos del vehículo en $t-1$, KLT calcula el emparejamiento para cada punto característico y como resultado genera un nuevo conjunto de puntos característicos correspondientes al vehículo en cuestión. Para llegar a conseguir un emparejamiento correcto el sistema se basa en votos de los puntos característicos que un objeto tiene asociado. A continuación se va a explicar más en detalle KLT.

Jean-Yves Bouguet [71] hicieron una implementación de KLT en la cual aplicaban KLT de forma recursiva sobre una pirámide de imágenes. Esta misma implementación es la que se ha empleado en este trabajo.

Lukas Kanade es un método diferencial y local en el que se analiza la vecindad de cada píxel. En él se asume que el flujo óptico es constante en una vecindad, y se resuelve la ecuación del flujo óptico para todos los píxeles en esta vecindad por el método de los mínimos cuadrados. Para el cálculo de los vectores de velocidad se emplea la siguiente fórmula:

$$\begin{bmatrix} u \\ v \end{bmatrix} = \begin{bmatrix} \sum_i I_{xi}^2 & \sum_i I_{xi}I_{yi} \\ \sum_i I_{xi}I_{yi} & \sum_i I_{yi}^2 \end{bmatrix}^{-1} \begin{bmatrix} -\sum_i I_{xi}I_{ti} \\ -\sum_i I_{yi}I_{ti} \end{bmatrix} \quad (4.6)$$

El vector (u, v) es el vector de desplazamiento del flujo óptico. I_x es la media del gradiente en x entre dos imágenes consecutivas, es decir, si $I(t)$ es la imagen del instante actual e $I(t + 1)$ es la imagen en el instante siguiente, la I_x de estos fotogramas es:

$$I_x = \frac{I_x(t) + I_x(t+1)}{2} \quad (4.7)$$

$I_x(t)$ es el gradiente en el eje x de la imagen $I(t)$ e $I_x(t+1)$ es el gradiente en x de la imagen $I(t+1)$. I_y es la media de los gradientes en y de la imagen $I(t)$ e $I(t+1)$:

$$I_y = \frac{I_y(t) + I_y(t+1)}{2} \quad (4.8)$$

I_t es la diferencia entre $I(t)$ suavizada e $I(t+1)$ suavizada:

$$I_t = I'(t+1) - I'(t) \quad (4.9)$$

Tal y como se ha dicho KLT se aplica en forma de *kernels* de tamaño $\omega \times \omega$ a lo largo de la imagen. El tamaño de los *kernels* debe ser definido en función de la cantidad de movimiento que tenga la imagen. Un valor de *kernel* pequeño será idóneo para evaluar desplazamientos pequeños de un punto. El uso de un tamaño grande de *kernel* aumenta el riesgo de obtener un error, pero hay en casos en los que el desplazamiento de un punto es muy grande y esto es necesario.

En la Figura 4.11 se puede ver cómo funciona KLT de forma piramidal.

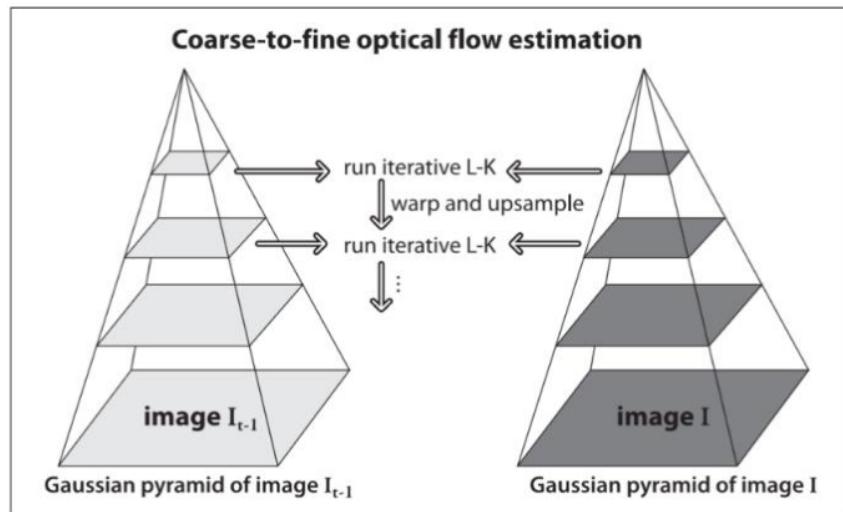


Figura 4.11: KLT Piramidal

Gracias al empleo de KLT piramidal se pueden estimar grandes desplazamientos con un tamaño de ventana muy pequeño.

4.4.3. Resumen General del Sistema

4.5. Estimación de la Velocidad

Smart-Traffic-Sensor tiene opciones para configurar la cámara, es decir para realizar su calibración. Al tener información de la cámara empleada tendremos información 3D de la imagen. Es decir podemos realizar una proyección al mundo 3D de nuestros puntos en la imagen.

Para calcular la velocidad sólo necesitamos conocer la distancia que ha recorrido el vehículo y el tiempo que ha tardado en hacerlo. Disponemos de una zona de evaluación por la cual discurren los vehículos, por tanto podemos saber cuánta distancia recorre por dicha zona de evaluación, y el tiempo que tarda en hacerlo. Para calcular la distancia tenemos que calcular la posición 3D de los vehículos y con ella hacer su diferencia. Esto se puede llevar a cabo haciendo uso de su homografía, la cual podemos estimar gracias a que conocemos los parámetros de la cámara.

Capítulo 5

Conclusiones

A lo largo de toda la memoria se ha explicado todo el proyecto realizado. Se han abordado todos los pasos que se han llevado a cabo; desde el comienzo en el que se parte de la literatura de otros autores hasta los experimentos sobre nuestro propio sistema. Es decir, se ha dado una visión general de todo lo que se ha hecho para llegar a tener nuestro *Smart-Traffic-Sensor*.

En este capítulo se va a realizar un resumen general del trabajo realizado y las conclusiones a las que se ha llegado. Finalmente se plantearán sus posibles líneas futuras.

5.1. Conclusiones

Este trabajo parte de una versión previa denominada *Traffic-Monitor* [17]. En ella se plantea una solución clásica para la monitorización de vehículos. El objetivo principal de *Smart-Traffic-Sensor* es mejorar los resultados respecto a los que se obtienen con *Traffic-Monitor*. Para ello se plantearon dos objetivos:

- Realizar la monitorización haciendo uso de técnicas más actuales como *Deep Learning*.
- Ofrecer la posibilidad de emplear diferentes *framework* de *Deep Learning* para la detección y clasificación. Es decir, poder emplear redes neuronales entrenadas con diferentes *frameworks* en *Smart-Traffic-Sensor*. En concreto, tener la posibilidad de usar redes entrenadas con *Keras*, *TensorFlow* y *Darknet*.
- Dotar al sistema de mayor robustez ante diversidad de imágenes tales como imágenes con mala calidad o con condiciones meteorológicas adversas.

CAPÍTULO 5. CONCLUSIONES

Ambos objetivos se han tenido en cuenta a lo largo de todo el trabajo, diseñando un sistema capaz de monitorizar vehículos basándonos principalmente en las detecciones que se obtienen mediante redes neuronales y dotándole de la capacidad de detectar vehículos en diferentes tipos de imágenes.

Tras evaluar nuestro trabajo se han podido extraer algunas conclusiones:

- Cuanta más información empleamos en el entrenamiento, mayor versatilidad tendremos.
- El tamaño de los vehículos influye a la hora de realizar las detecciones. Cuanto más pequeños sean los vehículos mayor dificultad habrá para detectarlos. Esta cuestión afecta directamente a las motocicletas, las cuales de por si poseen menor tamaño. Este hecho hace que en cuanto se alejen un poco su tamaño quede muy reducido, haciendo muy difícil su detección.
- Las clases de las que poseemos mayor cantidad de datos en el entrenamiento normalmente obtienen mejores resultados, pues se tiene mayor información acerca de ellas.

A continuación vamos a hacer un repaso de los resultados respecto a la detección de vehículos que hemos encontrado en la diferente literatura publicada. Para ver con ello si los resultados que obtenemos son comparables con los que se están publicando.

Y. Abdullah, G. Mehmet, A. Iman and B. Erkan [3] propusieron dos soluciones. Una con Faster R-CNN y otra con R-CNN. En su artículo indican el mAP obtenido para dos conjuntos de datos tanto con Faster R-CNN como con R-CNN. Esto se puede ver en la Tabla 5.1.

Método	mAP
Faster R-CNN (Dataset 1)	0.728
Faster R-CNN (Dataset 2)	0.757
R-CNN (Dataset 1)	0.647
R-CNN (Dataset 2)	0.657

Tabla 5.1: Resultados de Y. Abdullah, G. Mehmet, A. Iman and B. Erkan [3]

L. Chen, F. Ye, Y. Ruan, H. Fan and Q. Chen [72] usan *k-means* para obtener características de las imágenes y emplearlas durante el entrenamiento. Además concatenan

características de diferentes tamaños de imagen. Para realizar la detección emplean CNN. En la Tabla 5.2 se puede ver el mAP obtenido con su diseño, así como los resultados que ha obtenido con otro tipo de redes neuronales.

Método	mAP
Fast R-CNN	0.672
Faster R-CNN	0.692
YOLO	0.589
SSD300	0.688
SSD512	0.712
Diseño Implementado	0.757

Tabla 5.2: Resultados de Y. Abdullah, G. Mehmet, A. Iman and B. Erkan [3]

Ricardo Guerrero-Gómez-Olmedo, Roberto López-Sastre, Saturnino Maldonado-Bascón and Antonio Fernández-Caballero [53] plantean el uso de filtros de Kalman para realizar el seguimiento y descriptores HOG para la detección y clasificación. En su artículo dicen que la máxima precisión que obtuvieron era de 0.4872.

Albert Soto [73] propone el uso de YOLO para la detección de vehículos y llega a obtener una precisión de 0.5893 y un recall de 0.4092.

Viendo todos estos resultados se puede observar que *Smart-Traffic-Sensor* consigue superarlos. Con ello podemos afirmar que hemos llegado a obtener un sistema muy robusto y que aparentemente su calidad es suficientemente buena. Además hemos cumplido con creces el objetivo de mejorar los resultados que ofrecía *Traffic-Monitor*. Dicha aplicación permitía diferenciar entre 5 tipos de vehículos. No existía la diferenciación entre los tres tipos de camiones, sino que se trataban como una única categoría.

5.2. Trabajos Futuros

En esta sección se van a comentar posibles líneas futuras de este proyecto.

La base de datos que se ha empleado tan solo tiene vehículos que se ven por su parte trasera. Por tanto todo el trabajo realizado solo se ha centrado en secuencias de vídeos en las que los vehículos se ven por su parte trasera. Esto podría extenderse a diversas

CAPÍTULO 5. CONCLUSIONES

posiciones de los vehículos, desde vehículos que se vean por la parte frontal hasta vehículos que se vean de forma lateral. Con ello se conseguiría enriquecer la base de datos y por tanto obtener un modelo mucho más versatil que funcionará con cualquier disposición de los vehículos.

En este caso se han incluido imágenes con condiciones meteorológicas malas, pero solo se han incluido imágenes de lluvia y niebla, pues no se consiguió obtener una base de datos con otras condiciones. Se deberían incluir imágenes con mayores condiciones de niebla, con nieve , con borrascas, etc. Es decir, condiciones mucho más adversas para ver si es capaz de seguir comportándose bien.

Otra línea posible es dar el paso hacia la detección de vehículos en condiciones nocturnas, aunque en esta cuestión sería necesario el uso de cámaras infrarrojas.

En cuanto a las redes neuronales empleadas, hubiera sido muy interesante poder realizar una red propia, con la que poder hacer las detecciones y clasificaciones de los vehículos.

Finalmente se puede decir que por supuesto el sistema se podría mejorar en cuanto a los resultados obtenidos y ampliarlo incluyendo información acerca de lo que ocurre en la carretera, es decir, se podría detectar accidentes o comportamientos sospechosos.

Bibliografía

- [1] D. Koller, J. Weber and J. Malik. Robust multiple car tracking with occlusion reasoning. *University of California at Berkeley 1:188-196*, 1994.
- [2] Zezhi Chen and Tim Ellis. Multi-shape descriptor vehicle classification for urban traffic. *International Conference on Digital Image Computing: Techniques and Applications*, pages 465–461, 2011.
- [3] Y. Abdullah, G. Mehmet, A. Iman and B. Erkan. A Vehicle Detection Approach using Deep Learning Methodologies. *Computer Engineering Department Ankara University*, 2018.
- [4] M. Onoe and K. Ohba . Digital analysis of traffic flow. In *Proc Int Joint ConfPattern Recognition*, pages 803–804, 1976.
- [5] E.E. Hilbert, C. Carl, W. Goss, G.R. Hansen and M.J. Olsasky. Wide area detection system. *Report - Federal Highway Administration. FHWA-RD-77-86*, 1978.
- [6] N. Hoose. Queue detection using computer image processing.Road TrafficMonitoring. *Second International Conference on*, pages 94–98, 1989.
- [7] J.M Blosseville, C. Krafft, F. Lenior, V. Motyka and S. Beucher. New traffic measurement by image processing. *IFAC Control, Computers, Communicationsin Transportation*, pages 35–42, 1989.
- [8] J. Versavel, F. Lemaire and D. Van der Stede. Camera and computer-aided traffic sensor.Road Traffic Monitoring. *Second International Conference on*, pages 66–70, 1989.
- [9] Baker, K.D Sullivan and G.D. Performance assessment of model-based nacking. In *Applications of Computer Vision, Proceedings*, pages 28–35. IEEE Workshop on , 1992.
- [10] G.D. Sullivan, K.D. Baker, A.D. Worral, C.I. Attwood and P.M. Remagnino. Model-based vehicle detection and classification using orthographic approximations. *IVC 15:649-654* , 1997.

CAPÍTULO 5. CONCLUSIONES

- [11] B. Coifman, D. Beymer, P. McLauchlan and J. Malik. Areal-time computer vision system for vehicle tracking and traffic surveillance. *Institute of Transportation Studies, University of California, Berkeley* , 1998.
- [12] E. Vermeulen. Automatic incident detection (AID) with thermal cameras. *FLIR Intelligent Transportation System* , 2014.
- [13] Y. Chang, Z. Su and L. Qian-Yu. A new traffic incident detection method under low-volume condition based on automatic vehicle identification. In *Fuzzy Systems and Knowledge Discovery (FSKD), 9th International Conference on*, pages 2853–2859, 2012.
- [14] E. Nateghinia and H. Moradi. Video-based multiple vehicle tracking at intersections. In *Robotics and Mechatronics (ICRoM), Second RSI/ISM International Conference on*, 2014.
- [15] M.S. Shirazi and B. T. Morris. Vision-based turning movement monitoring: count, speed amp; waiting time estimation. *IEEE Intelligent Transportation Systems Magazine* 8(1):23–34, 2016.
- [16] Redouane Kachach. *Monitorización visual automática de tráfico rodado*. PhD thesis, Universidad de Alicante. Instituto Universitario de Investigación Informática, 2016. [Accedido 20 de Mayo de 2019].
- [17] Redouane Kachach. Traffic-Monitor. <https://github.com/JdeRobot/traffic-monitor>. [Accedido 22 de Junio de 2019].
- [18] S.I. Arroyo, F. Safar and D. Oliva. Probabilidad de infracción de velocidad de vehículos utilizando visión artificial en cámaras de campo amplio. *IEEE Biennial Congress of Argentina (ARGENCON)*, 2016.
- [19] A.F. Granados and J. I. Marin .H . Detección de flujo vehicular basado en visión artificial. *Universidad Tecnológica de Pereira*, 2007.
- [20] J. Portillo, G. Sánchez, J. Olivares and H. Pérez. Detección de Movimiento de Vehículos en Secuencias de Video Basados en la Diferencia Absoluta entre Fotogramas y la Combinación de Bordes. *Instituto Politécnico Nacional, Sección de Estudios*

de Posgrado e Investigación, Escuela Superior de Ingeniería Mecánica y Eléctrica Unidad Culhuacán, 2013.

- [21] C. Stauffer and W.E. Grimson . Adaptive background mixture models for real-time tracking. *IEEE ICCV 2: 256–261*, 1999.
- [22] Zoran Zivkovic. Improved adaptive gaussian mixture model for background subtraction. *Pattern Recognition. Proceedings of the 17th International Conference on*, 2:28–31, 2004.
- [23] P. Barcellos, C.Bouvié, F.L.Escouto and J. Scharcanski . A novel video based system for detecting and counting vehicles at user-defined virtual loops. *Expert Systems with Applications*, 42(4):1845–1856, 2014.
- [24] J. W. Davis and A.F. Bobick . The representation and recognition of human movement using temporal templates. In *IEEE computer society conference on computer vision and pattern recognition*, pages 928–934, 1997.
- [25] Y. Xia, X. Shi, G.Song, Q. Geng and Y. Liu . Towards improving quality of video-based vehicle counting method for traffic flow estimation. *SignalProcess*, 120(C):672–681, 2014.
- [26] N. Buch, J. Orwell and S. Velastin . 3D Extended Histogram of Oriented Gradients (3DHOG) for Classification of Road Users in Urban Scenes. In *BMVC.British Machine Vision Association.*, 2009.
- [27] Bjorn Johansson, Johan Wiklund, Per-Erik Forssén and Gösta Granlund. Combining shadow detection and simulation for estimation of vehicle size andposition. *Pattern Recognition Letters*, 2009.
- [28] John Wood. Statistical Background Models with Shadow Detection for Video Based Tracking. *Linköping University, Department of Electrical Engineering, Computer Vision. Linköping University, The Institute of Technology*, 2007.
- [29] K. Kim, T.H. Chalidabhongse, D. Harwood and L. Davis. Real-time foreground–background segmentation using codebook model. *Elsevier, Real time imaging*, page 172–185, 2005.

- [30] M. Mazaheri and S. Mozaffari. Real time adaptive background estimation and road segmentation for vehicle classification. *IEEE*, page 1–6, 2011.
- [31] A. Elgammal, D. Harwood and L. Davis. Non-parametric model for background subtraction. *Proc. Eur. Conf. Comput. Vis. Part II, LNCS 1843:751–767*, 2000.
- [32] Rigoberto Vizcay. *Deep Learning para la Detección de Peatones y Vehículos sobre FPGA*. PhD thesis, Centro Universitario UAEM Valle de México, 2018. [Accedido 22 de Junio de 2019].
- [33] Ignacio Arriola. *Detección de objetos basada en Deep Learning y aplicada a vehículos autónomos*. PhD thesis, Universidad del País Vasco. Ingeniería computacional y sistemas inteligentes, 2018.
- [34] Shaoqing Ren, Kaiming He, Ross Girshick, and Jian Sun. Faster r-cnn: Towards real-time object detection with region proposal networks. *In Advances in neural information processing systems*, pages 91–99, 2015.
- [35] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. *In Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 770–778, 2016.
- [36] Shih-Hao Yu, Yung-Sheng Chen, Wen-Fong Hu and Jun-Wei Hsieh. An automatic traffic surveillance system for vehicle tracking and classification. *Lecture Notes in Computer Science Volume 2749:379–386*, 2003.
- [37] Jin-Cyuan Lai, Shih-Shinh Huang and Chien-Cheng Tseng . Image-based vehicle tracking and classification on the highway. *Green Circuits and Systems (ICGCS), 2010 International Conference on*, pages 666–670, 2010.
- [38] H. Asaidi , A. Aarab and M. Bellouki. Shadow elimination and vehicles classification approaches in traffic video surveillance context. *Elsevier*, 2014.
- [39] C.P. Papageorgiou, M. Oren and T. Poggio. A General Framework for Object Detection. *In Proceedings of the Sixth International Conference on Computer Vision, ICCV '98*, pages 555–562, 1998.

- [40] Navneet Dalal and Bill Triggs. Histograms of Oriented Gradients for Human Detection. *Computer Vision and Pattern Recognition, IEEE Computer Society Conference*, 1:886–893, 2005.
- [41] Bailing Zhang, Yifan Zhou and Hao PanTammam Tillo. Hybrid model of clustering and kernel autoassociator for reliable vehicle type classification. *Machine Vision and Applications*, pages 437–450, 2013.
- [42] L. Sirovich and M. Kirby. Low-dimensional procedure for the characterization of human faces. *Journal of the Optical Society of America*, 4:519–524, 1987.
- [43] Wei Wang, Yulong Shang, Jinzhi Guo and Zhiwei Qian. Real-time vehicle classification based on eigenface. *Consumer Electronics, Communications and Networks(CECNet)*:4292–4295, 2011.
- [44] Wook-Sun Shin, Doo-Heon Song and Chang-Hun Lee. Vehicle classification by road lane detection and model fitting using a surveillance camera. *Journal of Information Processing Systems*, 2009.
- [45] J.R. Quinlan. C4.5: Programs for machine learning. *Morgan Kaufmann Publishers, Inc.*, 1993.
- [46] Shuang Wang, Zhengqi Li, Haijun Zhang, Yuzhu Ji and Yan Li. Classifying vehicles with convolutional neural network and feature encoding. *2016 IEEE 14th International Conference on Industrial Informatics (INDIN)*, 2016.
- [47] Edgar Camilo Camacho Poveda. Sistema de monitoreo y clasificación de tráfico urbano en tiempo real a través de procesamiento digital de imágenes. *Universidad Nacional de Colombia. Departamento de Ingeniería Eléctrica y Electrónica. Bogotá, Colombia*, 2017.
- [48] D. Comaniciu, V. Ramesh and P. Meer. Kernel-based object tracking. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 25(5):564–575, 2003.
- [49] Stefan Duffner and Christophe Garcia. Pixeltrack: A fast adaptive algorithm for tracking non-rigid objects. *Elsevier, Real time imaging*, pages 2480–2487, 2013.
- [50] D.G. Lowe. Distinctive image features from scale-invariant keypoints. *Int. J. Comput. Vision*, 60(2):91–110, 2004.

- [51] J. Shi and C. Tomasi. Good features to track. *Proc. IEEE CVPR*, pages 593–600, 1994.
- [52] M.J. Leotta and J.L. Mundy. Vehicle surveillance with a generic, adaptative, 3d vehicle model. *IEEE Transactions on pattern analysis and machine intelligence*, 33:1457-1469, 2011.
- [53] Saturnino Maldonado-Bascón Ricardo Guerrero-Gómez-Olmedo, Roberto López-Sastre and Antonio Fernández-Caballero. Vehicle Tracking by Simultaneous Detection and Viewpoint Estimation. <http://agamenon.tsc.uah.es/Personales/rlopez/docs/iwinac13-guerrero.pdf>, 2013. [Accedido 22 de Junio de 2019].
- [54] GRAM Road-Traffic Monitoring. Dataset. <http://agamenon.tsc.uah.es/Personales/rlopez/data/rtm/>, 2013. [Accedido 22 de Junio de 2019].
- [55] BIT-Vehicle. Dataset. <http://iitlab.bit.edu.cn/mcislab/vehicledb/>, 2015. [Accedido 22 de Junio de 2019].
- [56] CarND-Vehicle-Detection. Dataset. <https://github.com/udacity/CarND-Vehicle-Detection>, 2017. [Accedido 22 de Junio de 2019].
- [57] CarND-Vehicle-Detection. Dataset. <https://github.com/udacity/self-driving-car/tree/master/annotations>, 2017. [Accedido 22 de Junio de 2019].
- [58] Vinay Sharma. DeepLearningSuite. <https://github.com/JdeRobot/DetectionSuite>, 2019. [Accedido 31 de Mayo de 2019].
- [59] Tensorflow. <https://github.com/tensorflow/tensorflow>. [Accedido 22 de Junio de 2019].
- [60] Keras: Deep Learning for humans. <https://github.com/keras-team/keras>. [Accedido 22 de Junio de 2019].
- [61] Darknet. <https://github.com/pjreddie/darknet>. [Accedido 22 de Junio de 2019].
- [62] Redouane Kachach. Traffic-Monitor-Lab. <https://github.com/JdeRobot/smart-traffic-sensor-lab>. [Accedido 22 de Junio de 2019].

CAPÍTULO 5. CONCLUSIONES

- [63] R. Guerrero-Gomez-Olmedo, R. J. Lopez-Sastre, S. Maldonado-Bascon, and A. Fernandez-Caballero. Vehicle tracking by simultaneous detection and viewpoint estimation. In *IWINAC 2013, Part II, LNCS 7931*, pages 306–316, 2013.
- [64] Darren. LabelImg. <https://github.com/tzutalin/labelImg>. [Accedido 22 de Junio de 2019].
- [65] TensorFlow Models. <https://github.com/tensorflow/models>. [Accedido 22 de Junio de 2019].
- [66] SSD Mobilenet V2 COCO Config. https://github.com/tensorflow/models/blob/master/research/object_detection/samples/configs/ssd_mobilenet_v2_coco.config. [Accedido 22 de Junio de 2019].
- [67] Wei Liu, Dragomir Anguelov, Dumitru Erhan, Christian Szegedy, Scott Reed, Cheng-Yang Fu and Alexander C. Berg. SSD: Single Shot MultiBox Detector. *Computer Vision – ECCV*, pages 21–37, 2016.
- [68] Shaoqing Ren, Kaiming He, Ross Girshick, Sun. Jian . Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, pages 1137 – 1149, 2016.
- [69] Pierluigi Ferrari. SSD: Single-Shot MultiBox Detector implementation in Keras. https://github.com/pierluigiferrari/ssd_keras. [Accedido 22 de Junio de 2019].
- [70] Joseph Redmon, Santosh Divvala, Ross Girshick and Ali Farhadi . You Only Look Once:Unified, Real-Time Object Detection. *University of Washington*, 2016.
- [71] Jean- Yves Bouguet. Pyramidal Implementation of the Lukas Kanade Feature tracker. *Intel Corporation, Micriprocessor Research Labs*, 2000.
- [72] L. Chen, F. Ye, Y. Ruan, H. Fan and Q. Chen. An algorithm for highway vehicle detection based on convolutional neural network. *Chen et al. EURASIP Journal on Image and Video Processing*, 2018.
- [73] Albert Soto. YOLO Object Detector for Onboard Driving Images. *Universitat Autónoma de Barcelona*, 2017.

CAPÍTULO 5. CONCLUSIONES

- [74] Tesla. https://www.tesla.com/es_ES/autopilot, 2019. [Accedido 19 de Junio de 2019].
- [75] Tesla pone coto al piloto automático en España. https://www.economiadigital.es/tecnologia-y-tendencias/tesla-pone-coto-al-piloto-automatico-en-espana_625493_102.html/, 2019. [Accedido 19 de Junio de 2019].
- [76] Raúl Álvarez. El coche autónomo de Google (Waymo) se vuelve completamente autónomo y por primera vez sale a la calle sin conductor. <https://www.xataka.com/automovil/el-coche-autonomo-de-google-waymo-se-vuelve-completamente-autonomo-y-por-primeravez>, 2017. [Accedido 19 de Junio de 2019].
- [77] Mesta Fusion: así funciona y multa el súper radar del futuro. <https://www.autopista.es/radares-dgt/articulo/mesta-fusion-asi-multa-funciona-video>, 2018. [Accedido 20 de Junio de 2019].
- [78] El radar que lo caza todo. <https://www.elmundo.es/motor/2016/04/26/571e535f468aeb301c8b45b0.html>, 2016. [Accedido 20 de Junio de 2019].
- [79] Gonzalo Gasca. Precisión y recuperación (Precision and recall). https://medium.com/@gogasca_95055/precision-y-recuperacion-precision-recall-dc3c92178d5b, 2018. [Accedido 22 de Junio de 2019].
- [80] Rafael Padilla. Metrics for object detection. <https://github.com/rafaelpadilla/Object-Detection-Metrics>, 2019. [Accedido 22 de Junio de 2019].
- [81] Julián Blasco. *Técnicas de estadística computacional para visión por computador*. PhD thesis, Universidad Nacional de Educación a Distancia, 2018. [Accedido 22 de Junio de 2019].
- [82] Sundar Pichai. Expertos en Tensorflow. <https://www.paradigmadigital.com/lineas-servicio/tensorflow/>. [Accedido 22 de Junio de 2019].
- [83] Deep Learning básico con Keras (Parte 1). <https://enmilocalfunciona.io/deep-learning-basico-con-keras-parte-1/>, 2018. [Accedido 22 de Junio de 2019].

CAPÍTULO 5. CONCLUSIONES

- [84] Jessica Fernández Martínez. *Aplicación para la mejora motora y cognitiva para personas con discapacidad mediante juegos simples interactivos.* PhD thesis, Universidad de Alcalá. Escuela Politécnica Superior, 2015. [Accedido 22 de Junio de 2019].
- [85] Python Software Foundation. Tutorial de Python. <http://docs.python.org.ar/tutorial/3/real-index.html>, 2017. [Accedido 22 de Junio de 2019].
- [86] GNOME. GNOME Developer Center. <https://developer.gnome.org/>. [Accedido 22 de Junio de 2019].
- [87] S. Avendaño and G. Castillo. *Detección y Reconocimiento de las Señas del Juego del Truco en Tiempo Real.* PhD thesis, Facultad de Ciencias Exactas y Naturales Universidad de Buenos Aires, 2012. [Accedido 22 de Junio de 2019].
- [88] Algoritmo EM. <https://ccc.inaoep.mx/~jagonzalez/ML/principal/node81.html>, 2011. [Accedido 22 de Junio de 2019].
- [89] Lili Huang and M. Barth. Real-time multi-vehicle tracking based on feature detection and color probability model. *Intelligent Vehicles Symposium (IV)*, pages 981–986, 2010.
- [90] Vicente Rodriguez. Machine learning in healthcare parte 2. <https://vincentblog.xyz/posts/machine-learning-in-healthcare-parte-2>. [Accedido 22 de Junio de 2019].
- [91] Arvind Jayaraman. Vehicle Detection Project. <https://github.com/ajayaraman/CarND-VehicleDetection>. [Accedido 22 de Junio de 2019].
- [92] Jorge E. Espinosa, Sergio A Velastin and John W. Branch. Vehicle Detection Using Alex Net and Faster R-CNN Deep Learning Models: A Comparative Study. *International Visual Informatics Conference IVIC 2017: Advances in Visual Informatics*, pages 3–15, 2017.